



Université 
de Montréal

TRAVAIL DIRIGÉ DE MAÎTRISE

UNIVERSITÉ DE MONTRÉAL

DÉPARTEMENT D'INFORMATIQUE ET DE RECHERCHE
OPÉRATIONNELLE (DIRO)

MAÎTRISE EN FINANCE MATHÉMATIQUE ET
COMPUTATIONNELLE

Présenté par

Noukpo Janvier SONINHEKPON

noukpo.janvier.soninhekpon@umontreal.ca

Titre :

**Intégration d'un générateur de scénarios
pour l'optimisation contex-
tuelle de portefeuille**

Direction du Travail Dirigé

Directeur : Prof. Fabian BASTIN
Professeur titulaire, Université de Montréal



MONTRÉAL (QUÉBEC), HIVER 2026

Dédicaces

Remerciements

Table des matières

<i>Notations générales</i>	vi
Introduction générale	1
1 Optimisation moyenne–variance pénalisée : fondements théoriques et implémentation	3
1.1 Cadre moyenne–variance et formulation pénalisée	3
1.2 Analyse théorique du problème pénalisé	3
1.2.1 Convexité, existence et unicité	4
1.2.2 Solution analytique sans contrainte de non-négativité	4
1.2.3 Comportement asymptotique en fonction de η	4
1.2.4 Conditions d’optimalité avec contraintes de non-négativité	5
1.3 Calibration du paramètre d’aversion au risque	5
1.3.1 Interprétation économique	5
1.3.2 Lien avec la formulation à rendement cible	5
1.3.3 Méthodes de calibration	6
1.4 Implémentation	6
1.4.1 Construction des données et analyse exploratoire	6
1.4.2 Résultats numériques	8
1.4.3 Analyse économique	9
1.4.4 Lecture en richesse	10
1.4.5 Comparaison au portefeuille équipondéré	11
2 Mesures de risque alternatives et robustesse classique	12
2.1 Mesures de risque fondées sur les queues de distribution	12
2.1.1 Cadre probabiliste	12
2.1.2 Value-at-Risk	13
2.1.3 Conditional Value-at-Risk	13
2.1.4 Formulation variationnelle de la CVaR	14
2.2 Optimisation du portefeuille avec la CVaR	14
2.2.1 Représentation variationnelle	14
2.2.2 Motivation pour l’approximation par scénarios	15
2.3 Approximation par scénarios : méthode SAA	15
2.3.1 Génération des scénarios	15
2.3.2 Formulation du problème d’optimisation	16
2.4 Analyse empirique du portefeuille CVaR pénalisé	17
2.4.1 Frontière rendement – risque de queue	17

2.4.2	Influence du paramètre de pénalisation sur l'allocation	18
2.4.3	Lecture en richesse	18
2.4.4	Comparaison des stratégies d'investissement	19
3	Optimisation contextuelle de portefeuille	21
3.1	Notion de contexte en finance	21
3.2	Décision de portefeuille conditionnelle au contexte	22
3.2.1	Rupture conceptuelle avec les chapitres précédents	22
3.2.2	Définition d'une politique de décision	23
3.2.3	Vérification détaillée des contraintes (cas typiques)	23
3.2.4	Régularité et propriétés souhaitables de la politique	24
3.3	Formulation mathématique du problème d'optimisation contextuelle	24
3.3.1	Distribution conditionnelle des rendements	25
3.3.2	Formulation générale : optimisation sur l'espace des politiques	25
3.3.3	Formulation générale : optimisation sur l'espace des politiques	26
3.3.4	Cas particulier : moyenne-variance pénalisé conditionnel	27
3.3.5	Cas particulier : CVaR pénalisée conditionnelle	27
3.4	Exemples concrets de décisions contextuelles : de la vie courante à l'allocation d'actifs	28
3.4.1	Généralisation contextuelle du problème de référence ($\mathcal{P}_0$)	28
3.4.2	Gestion de stock d'une petite épicerie : commande selon météo et calendrier	29
3.4.3	Choix d'un forfait de transport : voiture vs métro selon trafic et météo	30
3.4.4	Planification d'un micro-crédit : montant accordé selon profil et conjoncture	30
3.5	Implémentation et étude empirique	31
3.5.1	Construction du contexte et segmentation en régimes	31
3.5.2	Comparaison des performances des stratégies	32
3.5.3	Trajectoires de richesse réalisées	33
3.5.4	Influence du paramètre d'aversion au risque	34
3.5.5	Robustesse de la stratégie contextuelle	35
3.5.6	Interprétation économique	36
4	Intégration d'un générateur de scénarios à l'optimisation contextuelle	38
4.1	Formulation du problème sous incertitude de distribution	38
4.1.1	Cadre probabiliste général	39
4.1.2	Incertain sur la distribution et approximation par scénarios	39
4.1.3	Extension contextuelle	40
4.1.4	Formulation pénalisée sous scénarios	40
4.2	Génération de scénarios de rendements	41
4.2.1	Modèle stochastique des prix	41
4.2.2	Log-rendements, rendements simples et cohérence avec les chapitres précédents	42
4.2.3	Dynamique conditionnelle aux régimes de volatilité	43
4.2.4	Données utilisées pour le calibrage	44
4.2.5	Procédure de simulation Monte Carlo	44
4.2.6	Rôle économique du générateur de scénarios	45

4.3	Optimisation de portefeuille sous scénarios	45
4.3.1	Cadre de décision	46
4.3.2	Espérance empirique sous scénarios	46
4.3.3	Formulation moyenne-variance sous scénarios	47
4.3.4	Stratégie contextuelle sous scénarios	47
4.4	Implémentation	48
4.4.1	Calibrage du générateur et simulation des scénarios	48
4.4.1.1	Estimation des paramètres conditionnels par régime	48
4.4.1.2	Estimation de la dynamique des régimes	49
4.4.1.3	Décomposition de Cholesky et simulation Monte Carlo	49
4.4.1.4	Analyse des trajectoires simulées	50
4.4.2	Optimisation de portefeuille sous scénarios simulés	52
4.4.2.1	Chargement des objets issus du notebook 1 et recons- truction du contexte historique	52
4.4.2.2	Résolution sur la grille de pénalisation η	53
4.4.2.3	Comparaison détaillée des stratégies pour $\eta = 1$	53
4.4.2.4	Comparaison des trajectoires de richesse	54
4.4.2.5	Analyse de la richesse finale en fonction de η	55
4.4.2.6	Figures multi-trajectoires pour différentes valeurs de η	56
4.4.2.7	Sensibilité à la fenêtre de volatilité K	58
4.4.2.8	Sensibilité au nombre de scénarios M	59
4.4.2.9	Lecture croisée des résultats	61
4.4.2.10	Interprétation économique et financière	62
	<i>Conclusions et Perspectives</i>	63
	Références	65
	Références théoriques	65
	Références bibliographique liées au code	65
	References associées aux cellules de code	66

Notations générales

- ★ $\mathbf{1}$: Vecteur de $\mathbb{R}^N$ dont toutes les composantes sont égales à 1
- ★ $^\top$: Opérateur de transposition d'un vecteur ou d'une matrice
- ★ ∇_x : opérateur gradient par rapport à la variable $x = (x_1, \dots, x_N)^\top \in \mathbb{R}^N$, défini par

$$\nabla_x f(x) = \left(\frac{\partial f}{\partial x_1}(x), \dots, \frac{\partial f}{\partial x_N}(x) \right)^\top.$$

- ★ $\Sigma \succ 0$: la matrice Σ est symétrique définie positive, c'est-à-dire

$$\forall x \in \mathbb{R}^N \setminus \{0\}, \quad x^\top \Sigma x > 0.$$

- ★ MV : abréviation du modèle moyenne-variance de Markowitz.
- ★ $\text{VaR}_\alpha(X)$: valeur à risque (*Value-at-Risk*) au niveau $\alpha \in (0, 1)$ de la variable aléatoire X .
- ★ $\text{CVaR}_\alpha(X)$: valeur à risque conditionnelle (*Conditional Value-at-Risk*) au niveau $\alpha \in (0, 1)$ de la variable aléatoire X .
- ★ $\mathbb{R}$: ensemble des nombres réels
- ★ $(\Omega, \mathcal{F}, \mathbb{P})$: espace probabilisé, où Ω est l'ensemble des issues, $\mathcal{F}$ une tribu sur Ω et $\mathbb{P}$ une mesure de probabilité
- ★ $\mathbb{P}$: mesure de probabilité définie sur $(\Omega, \mathcal{F})$
- ★ $\mathbb{E}$: opérateur d'espérance mathématique associé à la mesure $\mathbb{P}$, défini pour une variable aléatoire intégrable X par

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) d\mathbb{P}(\omega)$$

- ★ $(x)_+$: partie positive d'un réel $x \in \mathbb{R}$, définie par

$$(x)_+ = \max(x, 0)$$

- ★ Φ : fonction de répartition de la loi normale centrée réduite, définie pour $z \in \mathbb{R}$ par

$$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

- ★ φ : densité de la loi normale centrée réduite, définie pour $z \in \mathbb{R}$ par

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$$

- ★ SAA : *Sample Average Approximation*, méthode consistant à approcher une espérance par une moyenne empirique calculée à partir d'un échantillon fini de scénarios
- ★ $r^{(i)}$: i -ième réalisation (ou scénario) du vecteur aléatoire des rendements
- ★ QP : (*Quadratic Programming*) désigne un problème d'optimisation quadratique convexe, typiquement de la forme

$$\min_x x^\top \Sigma x \quad \text{sous contraintes linéaires,}$$

- ★ LP : (*Linear Programming*) désigne un problème d'optimisation linéaire.
- ★ $r \sim \mathcal{N}(\mu, \Sigma)$: le vecteur aléatoire des rendements $r \in \mathbb{R}^N$ suit une loi normale multivariée de moyenne μ et de matrice de covariance Σ .
- ★ $\mathcal{C}$: espace mesurable des contextes.
- ★ $\pi : \mathcal{C} \rightarrow \mathbb{R}^N$: application de l'espace des contextes vers $\mathbb{R}^N$.
- ★ Π : ensemble de politiques admissibles, c'est-à-dire un sous-ensemble de l'ensemble des applications de $\mathcal{C}$ vers $\mathbb{R}^N$.
- ★ $(0, +\infty)^N := \{x \in \mathbb{R}^N : x_i > 0 \text{ pour tout } i = 1, \dots, N\}$.
- ★ $\|\cdot\|$: norme euclidienne sur $\mathbb{R}^d$, pour une dimension d adaptée au contexte.
- ★ $\mathcal{P}(\cdot | c)$: loi de probabilité conditionnelle sur $\mathbb{R}^N$.
- ★ $\ell : \mathbb{R}^N \times \mathbb{R}^N \rightarrow \mathbb{R}$: fonction mesurable.
- ★ VIX : indice de volatilité implicite du marché des options.
- ★ $\odot$: produit de Hadamard (produit élément par élément). Pour deux vecteurs $a, b \in \mathbb{R}^N$,

$$a \odot b = (a_1 b_1, \dots, a_N b_N)^\top.$$

Résumé

Introduction générale

La gestion de portefeuille constitue l'un des problèmes centraux de la finance quantitative. Depuis les travaux fondateurs de Markowitz [6, 7], l'allocation optimale d'actifs repose sur la formalisation du compromis entre rendement espéré et risque, traditionnellement mesuré par la variance du portefeuille. Ce cadre, à l'origine de la théorie moderne du portefeuille, a profondément influencé les développements ultérieurs en finance mathématique et demeure aujourd'hui un point de départ incontournable de l'analyse quantitative des stratégies d'investissement.

Dans ce mémoire, nous considérons un investisseur disposant d'un capital initial $W_0 > 0$, qu'il souhaite répartir entre N actifs financiers sur un horizon d'investissement donné. Les poids d'allocation $x \in \mathbb{R}^N$ appartiennent au simplexe

$$(1) \quad \Delta = \{x \in \mathbb{R}^N \mid \mathbf{1}^\top x = 1, x \geq 0\},$$

ce qui correspond à une contrainte budgétaire sans vente à découvert. Si R désigne le vecteur aléatoire des rendements des actifs, le rendement du portefeuille s'écrit $R_p = x^\top R$. Le problème directeur étudié dans ce mémoire consiste à déterminer une allocation optimale résolvant

$$(\mathcal{P}_0) \quad \min_{x \in \Delta} \mathcal{R}(R_p),$$

où $\mathcal{R}$ représente un critère reflétant les préférences de l'investisseur vis-à-vis du risque et du rendement.

Dans sa formulation classique, le modèle moyenne-variance pénalise la variance du portefeuille par un paramètre d'aversion au risque [5, 8]. Cette approche, élégante et analytiquement tractable, repose toutefois sur des hypothèses restrictives, notamment la symétrie du risque, et se révèle sensible à l'estimation des paramètres. Ces limites ont motivé l'introduction de mesures de risque alternatives telles que la Value-at-Risk et la Conditional Value-at-Risk, cette dernière présentant des propriétés de cohérence et de convexité particulièrement adaptées à l'optimisation [9, 10]. Par ailleurs, l'évidence empirique met en lumière des phénomènes de volatilité variable dans le temps, de ruptures structurelles et de changements de régime qui ne peuvent être pleinement capturés par un cadre statique ; les modèles à changement de régime introduits par Hamilton [4] et leurs applications à l'allocation d'actifs [1] soulignent l'importance de conditionner la décision d'investissement à l'état du marché. Dans cette perspective, l'optimisation robuste et les approches fondées sur la génération de scénarios constituent des outils essentiels pour intégrer explicitement l'incertitude de distribution et la sensibilité aux hypothèses de modèle [3].

L'organisation du mémoire suit une progression méthodologique construite autour du problème ($\mathcal{P}_0$). Le Chapitre 1 établit le socle en étudiant la formulation pénalisée du modèle moyenne–variance, en analysant ses propriétés théoriques, les différentes stratégies de calibration du paramètre d'aversion au risque, ainsi que son implémentation numérique. Le Chapitre 2 étend ensuite le cadre à des mesures de risque centrées sur les pertes extrêmes, en particulier la CVaR, et étudie sa résolution numérique via des approximations par échantillonnage. Le Chapitre 3 introduit une dimension conditionnelle en considérant des allocations dépendant d'un contexte de marché observable, afin de mieux tenir compte des changements de régime. Enfin, le Chapitre 4 intègre un générateur de scénarios dépendant de régimes, permettant d'évaluer la robustesse des stratégies obtenues face à l'incertitude de distribution et de comparer leurs performances hors échantillon. Cette progression vise à analyser comment les choix de modélisation influencent la structure des portefeuilles optimaux et leurs performances, tout en conservant une cohérence globale autour d'un même problème décisionnel initial.

OPTIMISATION MOYENNE–VARIANCE PÉNALISÉE : FONDEMENTS THÉORIQUES ET IMPLÉMENTATION

Ce chapitre établit le cadre de référence utilisé dans la suite du mémoire pour traiter le problème directeur ($\mathcal{P}_0$). Nous adoptons la formulation pénalisée du modèle moyenne–variance, dans laquelle l’aversion au risque est intégrée directement dans la fonction objectif à travers un paramètre $\eta > 0$. Après un bref rappel de la formulation classique à rendement cible, nous analysons les propriétés théoriques du problème pénalisé, discutons la calibration du paramètre d’aversion au risque et présentons son implémentation numérique.

1.1 Cadre moyenne–variance et formulation pénalisée

Dans le cadre du problème ($\mathcal{P}_0$), on note $\mu = \mathbb{E}[R]$ le vecteur des rendements espérés et $\Sigma = \text{Cov}(R)$ la matrice de covariance, supposée symétrique définie positive. Les allocations admissibles appartiennent au simplexe Δ défini en (1).

Historiquement, le modèle moyenne–variance est formulé comme un problème de minimisation de la variance sous contrainte d’un rendement minimal :

$$(1.1) \quad \min_{x \in \Delta} x^\top \Sigma x \quad \text{s.c.} \quad \mu^\top x \geq \mu^*.$$

Cette approche introduit une contrainte explicite sur le rendement espéré.

Dans ce mémoire, nous retenons la formulation pénalisée, qui consiste à résoudre

$$(1.2) \quad \min_{x \in \Delta} \eta x^\top \Sigma x - \mu^\top x,$$

où $\eta > 0$ représente le coefficient d’aversion au risque.

Cette écriture permet d’intégrer le compromis rendement–risque directement dans la fonction objectif et se prête plus naturellement aux extensions développées dans les chapitres suivants.

1.2 Analyse théorique du problème pénalisé

Nous étudions dans cette section les propriétés mathématiques du problème

$$(\mathcal{P}^{\text{MV}, \eta}) \quad \min_{x \in \Delta} \eta x^\top \Sigma x - \mu^\top x,$$

où $\eta > 0$ et $\Sigma \succ 0$.

1.2.1 Convexité, existence et unicité

La fonction objectif peut s'écrire

$$f(x) = \eta x^\top \Sigma x - \mu^\top x.$$

Comme Σ est symétrique définie positive, la forme quadratique $x \mapsto x^\top \Sigma x$ est strictement convexe. Le terme linéaire $-\mu^\top x$ est affine. Il s'ensuit que f est strictement convexe sur $\mathbb{R}^N$.

L'ensemble admissible Δ est convexe et compact. Par continuité de f , le problème admet au moins une solution optimale.

En l'absence de contraintes d'inégalité actives dégénérées, la stricte convexité de f implique l'unicité de la solution optimale.

1.2.2 Solution analytique sans contrainte de non-négativité

Considérons d'abord le problème simplifié

$$\min_{x \in \mathbb{R}^N} \eta x^\top \Sigma x - \mu^\top x \quad \text{s.c. } \mathbf{1}^\top x = 1.$$

On introduit le multiplicateur de Lagrange $\lambda \in \mathbb{R}$ et on définit

$$\mathcal{L}(x, \lambda) = \eta x^\top \Sigma x - \mu^\top x + \lambda(\mathbf{1}^\top x - 1).$$

Les conditions du premier ordre donnent

$$\nabla_x \mathcal{L}(x, \lambda) = 2\eta \Sigma x - \mu + \lambda \mathbf{1} = 0.$$

On obtient donc

$$x = \frac{1}{2\eta} \Sigma^{-1}(\mu - \lambda \mathbf{1}).$$

En imposant la contrainte budgétaire $\mathbf{1}^\top x = 1$, on détermine λ :

$$\mathbf{1}^\top \Sigma^{-1}(\mu - \lambda \mathbf{1}) = 2\eta.$$

On en déduit

$$\lambda = \frac{\mathbf{1}^\top \Sigma^{-1} \mu - 2\eta}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}.$$

La solution optimale s'écrit alors explicitement

$$(1.3) \quad x^*(\eta) = \frac{1}{2\eta} \Sigma^{-1} \left(\mu - \frac{\mathbf{1}^\top \Sigma^{-1} \mu - 2\eta}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \mathbf{1} \right).$$

1.2.3 Comportement asymptotique en fonction de η

L'expression (1.3) permet d'analyser l'effet du paramètre η . En effet :

Lorsque $\eta \rightarrow 0^+$, le terme de pénalisation du risque devient négligeable et l'allocation tend vers un portefeuille orienté principalement vers la maximisation du rendement espéré.

Lorsque $\eta \rightarrow +\infty$, le terme quadratique domine et l'allocation converge vers le portefeuille de variance minimale sous contrainte budgétaire.

Le paramètre η contrôle donc continûment le compromis rendement–risque.

1.2.4 Conditions d'optimalité avec contraintes de non-négativité

Dans le problème original, les contraintes $x \geq 0$ doivent être prises en compte. On introduit des multiplicateurs $\gamma \in \mathbb{R}^N$ associés aux contraintes d'inégalité.

Le Lagrangien s'écrit

$$\mathcal{L}(x, \lambda, \gamma) = \eta x^\top \Sigma x - \mu^\top x + \lambda(\mathbf{1}^\top x - 1) - \gamma^\top x.$$

Les conditions KKT sont :

$$\begin{cases} 2\eta \Sigma x - \mu + \lambda \mathbf{1} - \gamma = 0, \\ \mathbf{1}^\top x = 1, \\ x \geq 0, \\ \gamma \geq 0, \\ \gamma_i x_i = 0 \quad \forall i. \end{cases}$$

Ces conditions caractérisent la solution optimale. Elles impliquent que certains poids peuvent être nuls lorsque les contraintes d'inégalité sont actives, ce qui introduit des changements de régime dans la structure du portefeuille optimal.

1.3 Calibration du paramètre d'aversion au risque

Le paramètre $\eta > 0$ joue un rôle central dans la formulation pénalisée du modèle moyenne-variance. Il détermine l'arbitrage entre rendement espéré et risque et influence directement la structure du portefeuille optimal. La détermination d'une valeur pertinente de η constitue donc une étape essentielle de l'analyse.

1.3.1 Interprétation économique

Le problème (1.2) peut être interprété comme la maximisation d'une utilité quadratique de la forme

$$U(x) = \mu^\top x - \eta x^\top \Sigma x.$$

Le paramètre η mesure le degré d'aversion au risque de l'investisseur. Une valeur élevée de η conduit à une forte pénalisation de la variance et favorise des portefeuilles peu volatils. À l'inverse, une valeur faible privilégie la recherche de rendement.

Ainsi, η peut être interprété comme un coefficient de préférence individuelle reflétant le profil de risque de l'investisseur.

1.3.2 Lien avec la formulation à rendement cible

La formulation pénalisée est étroitement liée au problème classique consistant à minimiser la variance sous contrainte d'un rendement minimal μ^* définie en (1.1)

Sous des conditions régulières, il existe une correspondance entre la valeur de η et le niveau de rendement cible μ^* . En effet, pour chaque $\eta > 0$, la solution $x^*(\eta)$

induit un rendement espéré $\mu^\top x^*(\eta)$. Réciproquement, pour un rendement cible admissible, il est possible de déterminer une valeur de η produisant une allocation équivalente.

La formulation pénalisée peut ainsi être interprétée comme une paramétrisation continue de la frontière efficiente.

1.3.3 Méthodes de calibration

Plusieurs approches peuvent être envisagées pour déterminer une valeur opérationnelle de η .

Une première méthode consiste à explorer une grille de valeurs $\eta_1, \dots, \eta_K$ et à analyser l'évolution des portefeuilles optimaux ainsi que de leurs caractéristiques (rendement espéré, variance, ratio de Sharpe). Cette approche permet d'identifier une zone de stabilité et de sélectionner une valeur cohérente avec les objectifs de l'investisseur.

Une deuxième méthode consiste à calibrer η de manière à atteindre un objectif donné, par exemple un niveau de rendement cible ou une volatilité maximale admissible. On peut alors résoudre numériquement l'équation

$$\mu^\top x^*(\eta) = \mu^*$$

ou

$$\sqrt{x^*(\eta)^\top \Sigma x^*(\eta)} = \sigma^*,$$

au moyen d'une procédure de recherche unidimensionnelle (dichotomie, méthode de Newton).

Enfin, une troisième approche repose sur des critères empiriques hors échantillon, en sélectionnant la valeur de η maximisant une performance observée sur une période de validation.

1.4 Implémentation

1.4.1 Construction des données et analyse exploratoire

Nous considérons un univers composé de cinq actions technologiques américaines : AAPL, MSFT, AMZN, GOOG et META. La période d'étude couvre dix années, du 1^{er} janvier 2015 au 31 décembre 2025.

Les prix journaliers (cours de clôture) sont téléchargés depuis la base publique Stooq, puis alignés sur les dates communes à l'ensemble des actifs afin d'obtenir un panel cohérent sans valeurs manquantes. Les données sont ensuite sauvegardées localement afin de garantir la reproductibilité des résultats. Le notebook créé à cet effet est `code_fichiercsv_prix.ipynb`.

La Figure 1.4.1 représente l'évolution des prix journaliers sur la période considérée. On observe une tendance haussière marquée sur le long terme, interrompue par des phases de correction significatives, notamment lors de la crise sanitaire de 2020 et des épisodes de volatilité postérieurs.




FIGURE 1.4.1 – Prix journaliers (Close) des cinq actifs technologiques sur la période 2015–2025.

Afin d'estimer correctement le modèle moyenne–variance, nous calculons également les rendements journaliers. Deux définitions sont considérées :

$$R_t^{(i)} = \frac{P_t^{(i)}}{P_{t-1}^{(i)}} - 1, \quad r_t^{(i)} = \log \left(\frac{P_t^{(i)}}{P_{t-1}^{(i)}} \right).$$

La Figure 1.4.2 présente les log-rendements journaliers. Ces séries apparaissent centrées autour de zéro et mettent en évidence des épisodes de volatilité accrue, caractéristiques des marchés financiers.




FIGURE 1.4.2 – Log-rendements journaliers sur la période 2015–2025.

Dans la suite du chapitre, nous utiliserons principalement les rendements simples pour la formulation moyenne–variance classique, tandis que les log-rendements seront mobilisés à des fins de comparaison et d'analyse statistique.

1.4.2 Résultats numériques

À travers le notebook `code_chap1.ipynb`, le modèle moyenne–variance pénalisé a été résolu sur une grille quasi-continue de

$$\eta \in [10^{-2}, 10^2],$$

composée de 200 points équidistants en échelle logarithmique. Pour chaque valeur de η , nous calculons :

- ★ le rendement espéré annualisé $ER(\eta) = \mu^\top x^*(\eta)$,
- ★ la variance $Var(\eta) = x^*(\eta)^\top \Sigma x^*(\eta)$,
- ★ la volatilité $Vol(\eta) = \sqrt{Var(\eta)}$,
- ★ ainsi qu’une lecture en richesse $E[W_1(\eta)]$.

Les résultats sont produits à partir :

- des log-rendements annualisés ;
- des rendements simples annualisés.

La Figure 1.4.3 présente la frontière obtenue dans le cas des log-rendements.




FIGURE 1.4.3 – Frontière risque–rendement (log-rendements annualisés).

On observe une courbe croissante et concave typique du cadre moyenne–variance. Les extrêmes numériques sont :

- $\eta = 0.01$: $ER \approx 24.66\%$, $Vol \approx 32.80\%$;
- $\eta = 100$: $ER \approx 22.61\%$, $Vol \approx 24.53\%$.

La Figure 1.4.4 présente les résultats obtenus avec les rendements simples.




FIGURE 1.4.4 – Frontière risque–rendement (rendements simples annualisés).

Les valeurs extrêmes sont légèrement plus élevées en rendement, ce qui reflète la différence structurelle entre log-rendements et rendements simples.

1.4.3 Analyse économique

La Figure 1.4.5 illustre l'évolution des poids optimaux en fonction de $\log_{10}(\eta)$.




FIGURE 1.4.5 – Poids optimaux en fonction de $\log_{10}(\eta)$ (log-rendements).

Pour η très faible, le portefeuille est quasiment entièrement investi en AMZN. Cela est cohérent avec les estimations de rendement :

$$\mu_{AMZN}^{log} \approx 24.66\%,$$

qui constitue le rendement espéré le plus élevé de l'échantillon.

Le modèle se comporte alors comme un problème de maximisation pure du rendement.

Pour $\eta = 1$, nous obtenons :

$$ER \approx 23.08\%, \quad Vol \approx 25.02\%.$$

Le portefeuille devient diversifié, avec des pondérations positives sur plusieurs actifs. On observe une transition progressive vers une allocation plus équilibrée.

Lorsque η devient important, la variance domine l'objectif. Le portefeuille converge vers une structure proche du portefeuille de variance minimale, avec une volatilité stabilisée autour de 24.5%.

La transition observée dans la Figure 1.4.5 est continue mais non linéaire, ce qui reflète les contraintes long-only et les changements d'actifs contraints.

1.4.4 Lecture en richesse

La Figure 1.4.6 présente la richesse attendue à un an :

$$(1.4) \quad \mathbb{E}[W_1(\eta)] = W_0 \exp(ER(\eta)).$$

Cette relation découle de la définition des log-rendements. Si r_t^p désigne le log-rendement du portefeuille à la date t , alors

$$r_t^p = \log\left(\frac{W_t}{W_{t-1}}\right),$$

ce qui implique

$$W_t = W_0 \exp\left(\sum_{s=1}^t r_s^p\right).$$

À horizon unitaire, la richesse dépend donc exponentiellement du log-rendement du portefeuille. En notant $ER(\eta) = \mathbb{E}[r^p]$ le log-rendement espéré du portefeuille associé au paramètre η , on obtient l'approximation (1.4).




FIGURE 1.4.6 – Richesse attendue à un an en fonction de $\log_{10}(\eta)$ (log-rendements).

On observe une décroissance monotone de la richesse lorsque η augmente. Cela est naturel : plus la pénalisation du risque est forte, plus le rendement diminue.

Les valeurs caractéristiques sont :

- * $\eta = 0.01 : \mathbb{E}[W_1] \approx 1.2796 \times 10^6$;
- * $\eta = 1 : \mathbb{E}[W_1] \approx 1.2596 \times 10^6$;
- * $\eta = 100 : \mathbb{E}[W_1] \approx 1.2537 \times 10^6$.

1.4.5 Comparaison au portefeuille équipondéré

Le portefeuille équipondéré (log-rendements) présente :

$$ER_{EW} \approx 22.28\%, \quad Vol_{EW} \approx 25.68\%, \quad E[W_1] \approx 1.2496 \times 10^6.$$

Pour $\eta = 1$, le portefeuille optimisé domine simultanément :

Portefeuille	ER	Vol	$E[W_1]$
Optimisé ($\eta = 1$)	23.08%	25.02%	1.2596×10^6
Équipondéré	22.28%	25.68%	1.2496×10^6

Le portefeuille optimisé offre donc :

- * un rendement supérieur,
- * une volatilité inférieure,
- * une richesse attendue plus élevée.

Il domine ainsi le portefeuille naïf équipondéré.

MESURES DE RISQUE ALTERNATIVES ET ROBUSTESSE CLASSIQUE

Dans le Chapitre 1, nous avons étudié le problème d'allocation de portefeuille ($\mathcal{P}_0$) dans le cadre du modèle moyenne-variance de Markowitz [6]. Ce modèle propose une formalisation analytique du compromis entre rendement espéré et risque, ce dernier étant mesuré par la variance du rendement du portefeuille. Malgré son rôle fondateur en finance quantitative, cette approche présente certaines limites, notamment parce que la variance pénalise symétriquement les fluctuations positives et négatives et ne décrit pas explicitement le comportement des pertes extrêmes.

Afin de mieux capturer les risques associés aux scénarios défavorables, il est naturel de considérer des mesures de risque fondées sur les queues de distribution. Parmi celles-ci, la *Value-at-Risk* (VaR) et la *Conditional Value-at-Risk* (CVaR) occupent une place centrale dans la littérature financière et dans la pratique de la gestion des risques [2, 10]. En particulier, la CVaR possède des propriétés de cohérence et de convexité qui la rendent particulièrement adaptée aux problèmes d'optimisation.

L'objectif de ce chapitre est donc d'introduire ces mesures de risque alternatives et d'étudier leur utilisation dans des modèles d'allocation de portefeuille. Après avoir présenté les notions fondamentales de VaR et de CVaR, nous reformulerons le problème d'optimisation de portefeuille en remplaçant la variance par une mesure de risque basée sur la CVaR. Afin de rendre ces modèles opérationnels, nous adopterons une approche par *Sample Average Approximation* (SAA), qui permet d'approximer les quantités stochastiques à partir d'un ensemble fini de scénarios de rendements.

2.1 Mesures de risque fondées sur les queues de distribution

2.1.1 Cadre probabiliste

On considère un vecteur aléatoire de rendements

$$r \in \mathbb{R}^N$$

associé à N actifs financiers, et un vecteur de pondérations

$$x \in \mathbb{R}^N$$

représentant la composition d'un portefeuille.

Le rendement aléatoire du portefeuille est donné par

$$r_p = x^\top r.$$

Afin d'analyser le risque en termes de pertes, on introduit la variable aléatoire

$$L(x) = -r_p = -x^\top r,$$

appelée *perte du portefeuille*. Une valeur élevée de $L(x)$ correspond donc à un scénario défavorable pour l'investisseur.

Les mesures de risque présentées dans cette section sont définies à partir de la distribution de la variable aléatoire $L(x)$.

2.1.2 Value-at-Risk

La *Value-at-Risk* constitue l'une des premières tentatives de quantification du risque extrême à partir des quantiles de la distribution des pertes.

Définition 2.1 (Value-at-Risk [10]). Soit $\alpha \in (0, 1)$ un niveau de confiance. La Value-at-Risk du portefeuille x au niveau α est définie par

$$\text{VaR}_\alpha(x) = \inf \{ \ell \in \mathbb{R} \mid \mathbb{P}(L(x) \leq \ell) \geq \alpha \}.$$

La VaR correspond donc au quantile de niveau α de la distribution des pertes. Son interprétation est simple : avec une probabilité α , la perte du portefeuille ne dépasse pas $\text{VaR}_\alpha(x)$.

Malgré cette simplicité d'interprétation, la VaR présente certaines limitations théoriques importantes dans un cadre d'optimisation.

Proposition 2.1 (Limites de la VaR [2]). La Value-at-Risk n'est pas, en général, une mesure de risque cohérente. En particulier, elle ne satisfait pas la propriété de sous-additivité, ce qui peut conduire à des situations où la diversification augmente le risque mesuré.

Cette absence de sous-additivité rend la VaR peu adaptée à certains problèmes d'optimisation de portefeuille.

2.1.3 Conditional Value-at-Risk

Afin de remédier à ces limitations, la *Conditional Value-at-Risk* (CVaR), également appelée *Expected Shortfall*, a été introduite comme une mesure de risque plus robuste.

Définition 2.2 (Conditional Value-at-Risk [9]). Pour un niveau de confiance $\alpha \in (0, 1)$, la Conditional Value-at-Risk du portefeuille x est définie par

$$\text{CVaR}_\alpha(x) = \mathbb{E} [L(x) \mid L(x) \geq \text{VaR}_\alpha(x)].$$

La CVaR correspond à l'espérance conditionnelle des pertes situées dans la queue de distribution au-delà du quantile α . Elle fournit ainsi une information plus complète sur la gravité des scénarios défavorables.

Proposition 2.2 (Cohérence de la CVaR [2]). *La Conditional Value-at-Risk est une mesure de risque cohérente. Elle satisfait les propriétés de monotonie, de sous-additivité, d'homogénéité positive et d'invariance par translation.*

Ces propriétés rendent la CVaR particulièrement adaptée aux problèmes d'optimisation de portefeuille.

2.1.4 Formulation variationnelle de la CVaR

Un résultat fondamental dû à Rockafellar et Uryasev montre que la CVaR admet une représentation variationnelle particulièrement adaptée à l'optimisation numérique.

Théorème 2.1 (Formulation variationnelle de la CVaR [10]). *Pour toute variable aléatoire intégrable $L(x)$ et tout $\alpha \in (0, 1)$, on a*

$$\text{CVaR}_\alpha(x) = \min_{t \in \mathbb{R}} \left\{ t + \frac{1}{1 - \alpha} \mathbb{E}[(L(x) - t)_+] \right\},$$

où $(u)_+ = \max(u, 0)$.

Cette formulation introduit une variable auxiliaire t interprétée comme un seuil de perte. Elle transforme la CVaR en une fonction convexe, ce qui permet son intégration directe dans des problèmes d'optimisation stochastique.

Dans la suite du chapitre, cette représentation jouera un rôle fondamental pour construire des formulations numériques du problème d'optimisation de portefeuille fondées sur la CVaR.

2.2 Optimisation du portefeuille avec la CVaR

Dans le Chapitre 1, le problème d'allocation de portefeuille a été étudié sous la forme pénalisée

$$\min_{x \in \Delta} \eta x^\top \Sigma x - \mu^\top x,$$

Afin de mieux prendre en compte les pertes extrêmes, nous remplaçons maintenant la variance par la *Conditional Value-at-Risk*. On obtient alors le problème pénalisé

$$(2.1) \quad \min_{x \in \Delta} \eta \text{CVaR}_\alpha(x) - \mu^\top x.$$

Cette formulation conserve exactement la même structure que celle étudiée au Chapitre 1, la seule différence étant la mesure de risque utilisée.

2.2.1 Représentation variationnelle

D'après le résultat de Rockafellar et Uryasev (Théorème 2.1), la CVaR peut être exprimée sous la forme

$$\text{CVaR}_\alpha(x) = \min_{t \in \mathbb{R}} \left\{ t + \frac{1}{1-\alpha} \mathbb{E}[(L(x) - t)_+] \right\}.$$

En introduisant la variable auxiliaire t , le problème (2.1) peut être reformulé comme

$$\min_{x,t} \eta \left(t + \frac{1}{1-\alpha} \mathbb{E}[(-x^\top r - t)_+] \right) - \mu^\top x.$$

Cette formulation reste convexe, mais la présence de l'espérance empêche une résolution analytique directe.

2.2.2 Motivation pour l'approximation par scénarios

Dans la pratique, la distribution des rendements est inconnue et la quantité

$$\mathbb{E}[(L(x) - t)_+]$$

ne peut pas être calculée explicitement. Pour rendre le problème opérationnel, on introduit un ensemble fini de scénarios de rendements et on remplace l'espérance par une moyenne empirique. Cette approche, appelée *Sample Average Approximation* (SAA), sera étudiée dans la section suivante.

2.3 Approximation par scénarios : méthode SAA

La formulation obtenue dans la section précédente repose sur l'espérance

$$\mathbb{E}[(L(x) - t)_+],$$

qui dépend de la distribution des rendements financiers. Dans la pratique, cette distribution est inconnue et ne peut être estimée qu'à partir de données observées.

Pour rendre le problème d'optimisation calculable, on remplace donc l'espérance théorique par une moyenne empirique obtenue à partir d'un ensemble fini de scénarios. Cette approche est connue sous le nom de *Sample Average Approximation* (SAA) [11].

2.3.1 Génération des scénarios

Soit

$$r^{(1)}, r^{(2)}, \dots, r^{(M)}$$

un ensemble de M scénarios de rendements, où chaque vecteur

$$r^{(m)} \in \mathbb{R}^N$$

représente une réalisation possible des rendements des N actifs. La perte associée au portefeuille x dans le scénario m est alors

$$L^{(m)}(x) = -x^\top r^{(m)}.$$

En remplaçant l'espérance par une moyenne empirique, on obtient l'approximation

$$\mathbb{E}[(L(x) - t)_+] \approx \frac{1}{M} \sum_{m=1}^M (L^{(m)}(x) - t)_+.$$

La CVaR empirique devient alors

$$\text{CVaR}_\alpha^{(M)}(x) = \min_t \left\{ t + \frac{1}{(1-\alpha)M} \sum_{m=1}^M (L^{(m)}(x) - t)_+ \right\}.$$

2.3.2 Formulation du problème d'optimisation

En substituant cette approximation dans le problème (2.1), on obtient le problème empirique

$$\min_{x,t} \eta \left(t + \frac{1}{(1-\alpha)M} \sum_{m=1}^M (L^{(m)}(x) - t)_+ \right) - \mu^\top x,$$

sous les contraintes

$$x \in \Delta.$$

Afin d'obtenir une formulation linéaire, on introduit des variables auxiliaires

$$u_m \geq 0, \quad m = 1, \dots, M,$$

telles que

$$u_m \geq L^{(m)}(x) - t.$$

Le problème devient alors

$$\min_{x,t,u} \eta \left(t + \frac{1}{(1-\alpha)M} \sum_{m=1}^M u_m \right) - \mu^\top x$$

sous

$$u_m \geq -x^\top r^{(m)} - t, \quad u_m \geq 0,$$

et

$$x \in \Delta.$$

Cette formulation correspond à un *programme linéaire* pouvant être résolu efficacement à l'aide de solveurs d'optimisation tels que Gurobi ou Ipopt.

2.4 Analyse empirique du portefeuille CVaR pénalisé

Cette section présente les résultats numériques obtenus avec la méthode CVaR-SAA pénalisée introduite précédemment. Les expériences utilisent les mêmes données que celles du Chapitre 1, à savoir les prix journaliers de cinq actions technologiques (AAPL, MSFT, AMZN, GOOG et META) sur la période 2015–2025.

Les rendements utilisés sont les log-rendements journaliers. La construction des données ayant déjà été détaillée au Chapitre 1, nous ne répétons pas ici les graphiques correspondants.

L'objectif de cette section est d'étudier empiriquement :

- le compromis rendement / risque de queue obtenu avec la CVaR,
- l'influence du paramètre de pénalisation η sur la composition du portefeuille,
- la comparaison avec deux stratégies de référence : le portefeuille moyenne-variance pénalisé et le portefeuille équipondéré.

2.4.1 Frontière rendement – risque de queue

La Figure 2.4.1 représente la relation empirique entre le rendement espéré annualisé et la CVaR annualisée obtenue en faisant varier le paramètre de pénalisation η .

Chaque point de la courbe correspond à un portefeuille optimal pour une valeur donnée de η . La courbe met en évidence le compromis classique entre rendement et risque : les portefeuilles offrant un rendement plus élevé sont également associés à un risque de queue plus important.

Le portefeuille équipondéré est également représenté sur la figure. On observe qu'il se situe en dessous de la frontière obtenue par optimisation, ce qui signifie que l'approche CVaR pénalisée permet d'obtenir de meilleures combinaisons rendement- risque.




FIGURE 2.4.1 – Frontière empirique rendement – CVaR obtenue avec la méthode CVaR-SAA pénalisée.

2.4.2 Influence du paramètre de pénalisation sur l'allocation

La Figure 2.4.2 montre l'évolution des poids optimaux du portefeuille lorsque le paramètre de pénalisation η varie.

L'axe horizontal représente $\log_{10}(\eta)$ afin de couvrir un large intervalle de valeurs.

Pour de faibles valeurs de η , la pénalisation du risque est faible et le portefeuille devient fortement concentré sur l'actif offrant le rendement le plus élevé dans l'échantillon (ici AMZN).

Lorsque η augmente, la pénalisation du risque de queue devient plus importante et l'allocation se diversifie progressivement entre plusieurs actifs, notamment MSFT, AAPL et GOOG.

Cette figure illustre clairement le rôle du paramètre η , qui peut être interprété comme un paramètre d'aversion au risque de queue.




FIGURE 2.4.2 – Évolution des poids optimaux en fonction de $\log_{10}(\eta)$.

2.4.3 Lecture en richesse

Afin d'interpréter les résultats en termes économiques, nous traduisons le rendement annualisé en richesse attendue à horizon d'un an.


Si W_0 désigne la richesse initiale, la richesse attendue à un an est calculée à partir des log-rendements selon

$$W_1(\eta) = W_0 \exp(ER(\eta)).$$

La Figure 2.4.3 présente l'évolution de cette richesse attendue lorsque η varie.

On observe une décroissance monotone de la richesse lorsque η augmente. Ce résultat est intuitif : une pénalisation plus forte du risque conduit à choisir des portefeuilles plus prudents, ce qui réduit le rendement espéré.

La ligne horizontale correspond à la richesse obtenue avec le portefeuille équi-pondéré, qui sert ici de référence.

FIGURE 2.4.3 – Richesse attendue à un an en fonction de $\log_{10}(\eta)$.

2.4.4 Comparaison des stratégies d'investissement

Nous comparons maintenant l'évolution de la richesse réalisée pour trois stratégies : le portefeuille moyenne-variance pénalisé (Chapitre 1), le portefeuille CVaR pénalisé et le portefeuille équipondéré. La richesse réalisée est calculée à partir des log-rendements du portefeuille selon la relation

$$W_t = W_0 \exp \left(\sum_{s \leq t} r_s^p \right).$$

La Figure 2.4.4 représente l'évolution de la richesse sur l'ensemble de la période d'étude.

se réalisée (log-rendements) — MV pénalisé vs CVaR péna




FIGURE 2.4.4 – Évolution de la richesse réalisée : MV pénalisé vs CVaR pénalisé vs portefeuille équipondéré.

Afin de mieux visualiser les différences relatives de croissance entre les stratégies sur le long terme, la Figure 2.4.5 présente la même évolution en échelle logarithmique.




FIGURE 2.4.5 – Évolution de la richesse réalisée en échelle logarithmique.

Les résultats empiriques montrent que l'approche CVaR pénalisée permet de contrôler explicitement le risque de pertes extrêmes tout en conservant une performance attractive.

Le paramètre η joue un rôle central dans le compromis rendement-risque : des valeurs faibles conduisent à des portefeuilles concentrés et plus performants, tandis que des valeurs élevées produisent des portefeuilles plus diversifiés et moins exposés aux pertes extrêmes.

La comparaison avec les autres stratégies montre que le portefeuille optimisé peut générer une croissance de richesse supérieure à celle du portefeuille équipondéré, tout en permettant d'ajuster précisément le niveau de risque de queue.

OPTIMISATION CONTEXTUELLE DE PORTEFEUILLE

Les modèles d'optimisation de portefeuille étudiés aux Chapitres 1 et 2 reposent sur une prise de décision statique : l'allocation optimale est déterminée une fois pour toutes à partir d'une modélisation globale de la distribution des rendements. Qu'il s'agisse du modèle moyenne-variance de Markowitz ou des formulations fondées sur la Conditional Value-at-Risk (CVaR), la décision d'investissement est décrite par un vecteur de pondérations fixe

$$x \in \mathbb{R}^N.$$

Dans la pratique, les décisions d'allocation sont pourtant prises à partir d'informations observables avant l'investissement, telles que des indicateurs de marché, des mesures de volatilité ou des variables macroéconomiques. Ces informations, regroupées sous le terme de *contexte*, influencent la distribution conditionnelle des rendements futurs et peuvent être exploitées afin d'adapter les allocations aux conditions de marché.

Ce chapitre introduit un cadre d'optimisation dans lequel la décision dépend explicitement d'un contexte observable $c \in \mathcal{C}$. L'allocation n'est alors plus un vecteur fixe, mais une *politique de décision*

$$x = \pi(c),$$

qui associe à chaque contexte une allocation admissible.

Dans ce cadre, les formulations pénalisées étudiées aux Chapitres 1 (moyenne-variance pénalisé) et 2 (CVaR pénalisé) peuvent être généralisées en remplaçant le vecteur de décision x par une politique $\pi(c)$. Le chapitre formalise ce cadre d'optimisation contextuelle et propose une première implémentation empirique fondée sur une segmentation simple en régimes de marché.

3.1 Notion de contexte en finance

Dans le cadre de l'optimisation de portefeuille, on désigne par *contexte* toute information observable avant la prise de décision d'investissement et susceptible d'influencer la distribution des rendements financiers futurs. Formellement, le contexte est modélisé comme une variable aléatoire prenant ses valeurs dans un espace

$$c \in \mathcal{C},$$

où l'espace $\mathcal{C}$ regroupe l'ensemble des *états observables du marché à la date de décision*. Contrairement aux rendements, qui demeurent incertains au moment de l'investissement, le contexte est supposé connu lorsque l'allocation de portefeuille est déterminée.

Il est important de distinguer clairement l'information contextuelle de l'incertitude financière. L'incertitude concerne les réalisations futures des rendements, qui ne sont pas observables au moment de la décision et relèvent d'une modélisation probabiliste. À l'inverse, le contexte correspond à une information disponible ex ante, issue de l'observation du marché ou de l'environnement économique, et pouvant être intégrée directement dans le processus de décision. Cette distinction est fondamentale, car elle permet de conditionner la décision d'investissement à l'information réellement accessible à l'investisseur.

En pratique, le contexte peut prendre de nombreuses formes. Il peut inclure des mesures de volatilité implicite, reflétant les anticipations de risque du marché, des indicateurs macroéconomiques tels que les taux d'intérêt, l'inflation ou la croissance économique, ainsi que des facteurs de marché largement utilisés en gestion d'actifs, comme les facteurs de style ou de momentum. Le contexte peut également être constitué de signaux statistiques issus de modèles quantitatifs, construits à partir de données historiques et destinés à capter certaines régularités du marché.

L'hypothèse centrale adoptée dans ce chapitre est que le contexte est observé avant la prise de décision et qu'il influence la distribution conditionnelle des rendements financiers. Autrement dit, bien que les rendements futurs restent incertains, leur loi de probabilité dépend de l'état du marché décrit par le contexte. Cette hypothèse constitue le fondement de l'optimisation contextuelle, dans laquelle la décision d'allocation est adaptée aux informations disponibles au moment de l'investissement.

3.2 Décision de portefeuille conditionnelle au contexte

3.2.1 Rupture conceptuelle avec les chapitres précédents

Aux Chapitres 1 et 2, la décision d'investissement est modélisée par un vecteur de pondérations

$$x = (x_1, \dots, x_N)^\top \in \mathbb{R}^N,$$

choisi une fois pour toutes à partir d'une modélisation (globale) des rendements. Autrement dit, la décision est *statique* : elle ne dépend pas explicitement d'une information observable au moment où elle est prise.

Dans un cadre contextuel, l'investisseur observe d'abord un contexte $c \in \mathcal{C}$, puis choisit une allocation adaptée à ce contexte. La variable de décision n'est donc plus un vecteur constant, mais une règle d'allocation qui associe à chaque contexte une allocation admissible. On écrit alors

$$x \in \mathbb{R}^N \longrightarrow x = \pi(c),$$

où π est une *politique de décision*.

Cette transformation est fondamentale : elle remplace un problème d'optimisation sur un vecteur x par un problème d'optimisation sur une *fonction* π . Les modèles des Chapitres 1 et 2 deviennent des cas particuliers correspondant à une politique constante, c'est-à-dire $\pi(c) \equiv x$ pour tout $c \in \mathcal{C}$.

3.2.2 Définition d'une politique de décision

On appelle *politique de décision* toute application

$$\pi : \mathcal{C} \rightarrow \mathbb{R}^N$$

qui, à un contexte c , associe un vecteur de pondérations $\pi(c)$. Pour assurer une interprétation financière standard, l'allocation doit respecter des contraintes d'admissibilité (budget, absence de vente à découvert, etc.). On introduit donc l'ensemble admissible (simplexe)

$$(3.1) \quad \Delta := \left\{ x \in \mathbb{R}^N : \mathbf{1}^\top x = 1, x \geq 0 \right\},$$

où $\mathbf{1} \in \mathbb{R}^N$ est le vecteur dont toutes les composantes valent 1, et $x \geq 0$ signifie $x_i \geq 0$ pour tout i .

Une politique π est dite *admissible* si elle prend ses valeurs dans Δ , c'est-à-dire

$$\pi(c) \in \Delta, \quad \forall c \in \mathcal{C}.$$

Autrement dit, les contraintes financières doivent être satisfaites *pour tout contexte*. La contrainte budgétaire et la non-négativité deviennent alors les contraintes conditionnelles suivantes :

$$\mathbf{1}^\top \pi(c) = 1, \quad \pi(c) \geq 0, \quad \forall c \in \mathcal{C}.$$

3.2.3 Vérification détaillée des contraintes (cas typiques)

Afin de rendre la contrainte $\pi(c) \in \Delta$ exploitable, il est naturel de construire π à partir d'une application auxiliaire $z : \mathcal{C} \rightarrow \mathbb{R}^N$, puis de la *normaliser* de façon à obtenir automatiquement une allocation admissible.

(a) Construction par transformation softmax : Soit $z(c) = (z_1(c), \dots, z_N(c))^\top \in \mathbb{R}^N$. On définit

$$\pi_i(c) := \frac{\exp(z_i(c))}{\sum_{j=1}^N \exp(z_j(c))}, \quad i = 1, \dots, N.$$

Alors, pour tout $c \in \mathcal{C}$, on a :

$$\pi_i(c) \geq 0 \quad \text{car} \quad \exp(z_i(c)) > 0,$$

et

$$\mathbf{1}^\top \pi(c) = \sum_{i=1}^N \pi_i(c) = \sum_{i=1}^N \frac{\exp(z_i(c))}{\sum_{j=1}^N \exp(z_j(c))} = \frac{\sum_{i=1}^N \exp(z_i(c))}{\sum_{j=1}^N \exp(z_j(c))} = 1.$$

Ainsi $\pi(c) \in \Delta$ pour tout c , et les contraintes financières sont satisfaites *par construction*.

(b) Construction par normalisation positive : Si l'on impose $u(c) \in (0, +\infty)^N$, on peut aussi définir

$$\pi(c) := \frac{u(c)}{\mathbf{1}^\top u(c)}.$$

On vérifie immédiatement :

$$\pi(c) \geq 0 \quad \text{et} \quad \mathbf{1}^\top \pi(c) = \frac{\mathbf{1}^\top u(c)}{\mathbf{1}^\top u(c)} = 1.$$

Ce type de construction est utile lorsque $u(c)$ provient d'un modèle simple (interprétable) et doit ensuite être ramené dans le simplexe.

3.2.4 Régularité et propriétés souhaitables de la politique

Le passage à une décision $\pi(c)$ soulève des questions de régularité qui n'apparaissent pas dans le cadre statique. En pratique, plusieurs propriétés peuvent être exigées selon l'objectif poursuivi :

- * *Mesurabilité* : Pour que des expressions du type $\mathbb{E}[\ell(\pi(c), r)]$ soient bien définies, il est naturel d'exiger que π soit mesurable par rapport à la tribu générée par c . Cette hypothèse est standard dès qu'on manipule des espérances conditionnelles.
- * *Continuité / stabilité* : On souhaite souvent que des contextes proches conduisent à des allocations proches, afin d'éviter des décisions instables. Une hypothèse classique est la continuité, voire une condition de Lipschitz :

$$\|\pi(c) - \pi(c')\| \leq L \|c - c'\|, \quad \forall c, c' \in \mathcal{C},$$

où $L > 0$ est une constante. Cette propriété renforce la robustesse vis-à-vis des erreurs d'observation du contexte.

- * *Bornitude et contraintes supplémentaires* : Selon le marché considéré, on peut imposer des contraintes additionnelles, par exemple des bornes composante par composante :

$$0 \leq \pi_i(c) \leq \bar{x}_i, \quad \forall c \in \mathcal{C}, \forall i,$$

afin de limiter la concentration et d'améliorer l'interprétabilité des allocations.

En résumé, la décision contextuelle consiste à choisir une politique π reliant explicitement information observable et allocation, tout en garantissant l'admissibilité financière pour chaque contexte.

3.3 Formulation mathématique du problème d'optimisation contextuelle

Cette section formalise le problème central de l'optimisation contextuelle introduite aux Sections 3.1 et 3.2. L'idée clé est que, si le contexte c est observé avant la décision, alors la distribution des rendements futurs r doit être comprise *conditionnellement* à ce contexte, et la décision doit être optimisée en conséquence via une politique $\pi(\cdot)$.

3.3.1 Distribution conditionnelle des rendements

On note $r \in \mathbb{R}^N$ le vecteur aléatoire des rendements des N actifs sur l'horizon considéré, et $c \in \mathcal{C}$ le contexte observé avant la décision. L'hypothèse fondamentale de l'optimisation contextuelle est que la loi de r dépend de c , ce que l'on écrit formellement

$$r \mid c \sim \mathcal{P}(\cdot \mid c),$$

où $\mathcal{P}(\cdot \mid c)$ désigne une loi conditionnelle sur $\mathbb{R}^N$. Il est utile de distinguer deux niveaux d'aléa :

- ★ le contexte c , aléatoire *avant observation*, mais connu au moment de la décision;
- ★ les rendements r , qui restent aléatoires après la décision, mais dont la loi dépend de c .

Ainsi, toute mesure de performance ou de risque doit être interprétée via des quantités conditionnelles sachant c .

3.3.2 Formulation générale : optimisation sur l'espace des politiques

Dans les Chapitres 1 et 2, l'objectif consistait à choisir un vecteur d'allocation

$$x \in \mathbb{R}^N$$

minimisant une mesure de risque (variance, CVaR, etc.). Dans le cadre contextuel, la décision devient une politique

$$\pi : \mathcal{C} \rightarrow \mathbb{R}^N,$$

et l'allocation appliquée lorsque le contexte vaut c est

$$x = \pi(c).$$

Le problème central étudié dans ce chapitre consiste donc à déterminer une politique d'allocation qui minimise une mesure de risque moyenne sur les contextes et les rendements futurs.

Pour formaliser ce problème, on introduit une fonction de perte

$$\ell : \mathbb{R}^N \times \mathbb{R}^N \rightarrow \mathbb{R}, \quad (x, r) \mapsto \ell(x, r),$$

qui associe à une allocation x et à une réalisation des rendements r un coût réel.

Le problème d'optimisation contextuelle s'écrit alors sous la forme générale suivante :

$$(3.2) \quad \min_{\pi \in \Pi} \mathbb{E}[\ell(\pi(c), r)],$$

où Π désigne l'ensemble des politiques admissibles.

Cette formulation met en évidence la différence fondamentale avec les chapitres précédents : la variable de décision n'est plus un vecteur d'allocation fixe, mais une fonction reliant le contexte observable à une allocation de portefeuille.

En utilisant la loi de l'espérance totale, on obtient

$$\mathbb{E}[\ell(\pi(c), r)] = \mathbb{E}[\mathbb{E}[\ell(\pi(c), r) \mid c]].$$

Une fois c fixé, la décision $\pi(c)$ est déterministe et seule la variable $r \mid c$ reste aléatoire. On peut donc définir la fonctionnelle conditionnelle

$$g(\pi; c) = \mathbb{E}[\ell(\pi(c), r) \mid c],$$

et réécrire le problème sous la forme

$$\min_{\pi \in \Pi} \mathbb{E}[g(\pi; c)].$$

Les contraintes financières doivent être satisfaites pour tout contexte. En notant Δ l'ensemble admissible introduit en (3.1), on impose

$$\pi(c) \in \Delta, \quad \forall c \in \mathcal{C}.$$

3.3.3 Formulation générale : optimisation sur l'espace des politiques

Dans les Chapitres 1 et 2, l'objectif consistait à choisir un vecteur d'allocation

$$x \in \mathbb{R}^N$$

minimisant une mesure de risque. Dans le cadre contextuel, la décision devient une politique

$$\pi : \mathcal{C} \rightarrow \mathbb{R}^N,$$

et l'allocation appliquée lorsque le contexte vaut c est

$$x = \pi(c).$$

On introduit une fonction de perte

$$\ell : \mathbb{R}^N \times \mathbb{R}^N \rightarrow \mathbb{R}, \quad (x, r) \mapsto \ell(x, r),$$

qui associe à une allocation x et à une réalisation des rendements r un coût réel. Le problème d'optimisation contextuelle peut alors s'écrire sous la forme générale

$$(3.3) \quad \min_{\pi \in \Pi} \mathbb{E}[\ell(\pi(c), r)],$$

où Π désigne l'ensemble des politiques admissibles. En utilisant la loi de l'espérance totale, on obtient

$$\mathbb{E}[\ell(\pi(c), r)] = \mathbb{E}[\mathbb{E}[\ell(\pi(c), r) \mid c]].$$

Une fois c fixé, la décision $\pi(c)$ est déterministe et seule la variable $r \mid c$ reste aléatoire. On peut donc définir la fonctionnelle conditionnelle

$$g(\pi; c) = \mathbb{E}[\ell(\pi(c), r) \mid c],$$

et réécrire le problème sous la forme

$$\min_{\pi \in \Pi} \mathbb{E}[g(\pi; c)].$$

Les contraintes financières doivent être satisfaites pour tout contexte. En notant Δ l'ensemble admissible introduit en (3.1), on impose

$$\pi(c) \in \Delta, \quad \forall c \in \mathcal{C}.$$

3.3.4 Cas particulier : moyenne–variance pénalisé conditionnel

On relie maintenant la formulation contextuelle aux modèles moyenne–variance pénalisés étudiés au Chapitre 1. Pour un contexte c donné, on définit la moyenne conditionnelle et la covariance conditionnelle des rendements :

$$\mu(c) = \mathbb{E}[r \mid c] \in \mathbb{R}^N, \quad \Sigma(c) = \text{Cov}(r \mid c) \in \mathbb{R}^{N \times N}.$$

Pour une allocation $x = \pi(c)$, la variance conditionnelle du portefeuille est

$$\text{Var}(x^\top r \mid c) = \pi(c)^\top \Sigma(c) \pi(c).$$

Dans le même esprit que la formulation pénalisée introduite au Chapitre 1, on considère alors le problème d'optimisation contextuelle suivant :

$$(3.4) \quad \min_{\pi \in \Pi} \mathbb{E} \left[\eta \pi(c)^\top \Sigma(c) \pi(c) - \pi(c)^\top \mu(c) \right],$$

où $\eta > 0$ est un paramètre de pénalisation contrôlant le compromis entre risque et rendement.

Cette formulation constitue une extension naturelle du modèle moyenne–variance pénalisé au cas où les paramètres du modèle dépendent du contexte observé.

3.3.5 Cas particulier : CVaR pénalisée conditionnelle

On relie maintenant la formulation contextuelle aux modèles fondés sur la Conditional Value-at-Risk étudiés au Chapitre 2. On définit la perte du portefeuille par

$$L(\pi(c), r) = -\pi(c)^\top r.$$

Pour un niveau de risque $\alpha \in (0, 1)$, la CVaR conditionnelle de cette perte sachant le contexte c peut s'écrire sous la forme de Rockafellar–Uryasev :

$$(3.5) \quad \text{CVaR}_\alpha(L(\pi(c), r) \mid c) = \min_{\tau \in \mathbb{R}} \left\{ \tau + \frac{1}{1 - \alpha} \mathbb{E}[(L(\pi(c), r) - \tau)_+ \mid c] \right\}.$$

Dans le même esprit que la formulation pénalisée étudiée au Chapitre 2, on considère alors le problème contextuel suivant :

$$(3.6) \quad \min_{\pi \in \Pi} \mathbb{E} \left[\eta \text{CVaR}_\alpha(L(\pi(c), r) \mid c) - \pi(c)^\top \mu(c) \right],$$

où $\eta > 0$ est un paramètre de pénalisation contrôlant le compromis entre risque de queue et rendement espéré.

Comme précédemment, la décision d'allocation dépend désormais du contexte via la politique $\pi(c)$, ce qui permet d'adapter le portefeuille aux conditions de marché observées.

3.4 Exemples concrets de décisions contextuelles : de la vie courante à l'allocation d'actifs

Cette section présente plusieurs situations concrètes dans lesquelles une décision doit être prise *en fonction d'un contexte observable* (information disponible avant la réalisation de l'aléa). L'objectif est double :

- * expliciter clairement les objets $c, \mathcal{C}, \pi(c), \Pi$,
- * fournir des formulations directement exploitables pour l'implémentation numérique.

Dans tous les exemples ci-dessous :

- * $c \in \mathcal{C}$ désigne le *contexte* (variables observables au moment de décider),
- * r désigne l'*incertitude* (rendements, demande, prix, etc.),
- * π est une *politique* : $\pi : \mathcal{C} \rightarrow \mathcal{X}$,
- * $\pi(c)$ est la *décision* prise lorsque le contexte vaut c ,
- * Π est l'ensemble des politiques admissibles (contraintes structurelles),
- * la performance est mesurée via une perte $\ell(\pi(c), r)$.

3.4.1 Généralisation contextuelle du problème de référence ($\mathcal{P}_0$)

On considère un investisseur qui répartit un capital entre trois classes d'actifs représentatives d'un portefeuille standard à horizon annuel : *obligations*, *actions domestiques* et *actions internationales*. Contrairement au cadre statique du problème ($\mathcal{P}_0$), l'investisseur observe avant la décision un ensemble d'informations macro-financières décrivant l'état du marché. Ces informations, regroupées dans un vecteur de contexte c , influencent directement les rendements espérés et les dépendances entre actifs. Ignorer ce contexte revient à supposer implicitement que le marché est stationnaire, hypothèse rarement vérifiée empiriquement.

On définit

$$r = (r_1, r_2, r_3)^\top \in \mathbb{R}^3, \quad x = \pi(c) = (x_1, x_2, x_3)^\top \in \mathbb{R}^3.$$

et un vecteur de contexte $c \in \mathbb{R}^p$ regroupant des indicateurs observables au début de l'année, par exemple (illustration) :

$$c = (\text{taux court, inflation, VIX, spread crédit})^\top \in \mathbb{R}^4.$$

L'espace des contextes est donc

$$\mathcal{C} \subset \mathbb{R}^p.$$

Une politique π associe à chaque contexte une allocation :

$$\pi : \mathcal{C} \rightarrow \mathbb{R}^3, \quad c \mapsto \pi(c).$$

On impose les contraintes *pour tout contexte* :

$$\Pi = \left\{ \pi : \mathcal{C} \rightarrow \mathbb{R}^3 : \mathbf{1}^\top \pi(c) = 1, \pi(c) \geq 0, \mu(c)^\top \pi(c) \geq \mu^*, \forall c \in \mathcal{C} \right\},$$

où $\mu^* = 8\%$.

Au lieu d'un unique couple (μ, Σ) comme dans $(\mathcal{P}_0)$, on considère des quantités conditionnelles :

$$\mu(c) = \mathbb{E}[r \mid c] \in \mathbb{R}^3, \quad \Sigma(c) = \text{Var}(r \mid c) \in \mathbb{R}^{3 \times 3}.$$

Un analogue direct de $(\mathcal{P}_0)$ consiste à minimiser une variance conditionnelle sous contrainte de rendement :

$$(\mathcal{P}_0^{\text{ctx}}) \quad \min_{\pi \in \Pi} \mathbb{E}[\pi(c)^\top \Sigma(c) \pi(c)],$$

ou, de manière équivalente *point par point* en contexte :

$$\text{pour tout } c \in \mathcal{C}, \quad \min_{x \in \mathbb{R}^3} x^\top \Sigma(c) x \quad \text{s.c.} \quad \mathbf{1}^\top x = 1, x \geq 0, \mu(c)^\top x \geq \mu^*.$$

Les approches classiques (sans contexte) produisent un unique portefeuille x optimisé pour un couple fixe (μ, Σ) . Dans un environnement où :

$$\mu(c) \text{ et } \Sigma(c) \text{ changent fortement avec } c,$$

un portefeuille unique devient un compromis « moyen » :

- ▷ trop prudent en régime favorable (opportunités manquées),
- ▷ trop risqué en régime défavorable (pertes hors échantillon),
- ▷ et il peut violer la contrainte $\mu(c)^\top x \geq \mu^*$ pour certains contextes.

La politique contextuelle $\pi(c)$ permet au contraire d'ajuster la décision au régime observé.

3.4.2 Gestion de stock d'une petite épicerie : commande selon météo et calendrier

Une épicerie choisit la quantité à commander d'un produit périssable (pain, fruits) en fonction du contexte : jour de semaine, météo, période de paie, événement local.

$$r = \text{demande du jour} \in \mathbb{R}_+, \quad x = \pi(c) = \text{quantité commandée} \in [0, x_{\max}].$$

et

$$\begin{aligned} c &= (\text{jour, température, pluie, événement}) \in \mathcal{C} \\ \Pi &= \left\{ \pi : \mathcal{C} \rightarrow [0, x_{\max}] \right\} \end{aligned}$$

Avec coût de rupture $p > 0$ et coût d'inventaire $h > 0$,

$$\ell(x, r) = p(r - x)_+ + h(x - r)_+.$$

Le problème contextuel :

$$\min_{\pi \in \Pi} \mathbb{E}[\ell(\pi(c), r)].$$

Ce problème est directement implémentable par SAA via des scénarios (c_i, r_i) .

3.4.3 Choix d'un forfait de transport : voiture vs métro selon trafic et météo

Une personne décide chaque matin du mode de transport (voiture, métro, bus) selon le contexte : météo, trafic, horaire, travaux sur la ligne.

$$x = \pi(c) \in \{1, 2, 3\},$$

où 1=voiture, 2=métro, 3=bus.

$$\begin{aligned} c &= (\text{météo, trafic, heure, travaux}) \in \mathcal{C} \\ r &= \text{temps de trajet réel} \quad \text{et/ou} \quad r = \text{coût réel} \\ \Pi &= \{\pi : \mathcal{C} \rightarrow \{1, 2, 3\}\} \end{aligned}$$

L'objectif est donc le suivant :

$$\min_{\pi \in \Pi} \mathbb{E}[\alpha \text{Temps}(\pi(c), r) + (1 - \alpha) \text{Coût}(\pi(c), r)], \quad \alpha \in (0, 1).$$

3.4.4 Planification d'un micro-crédit : montant accordé selon profil et conjoncture

Une institution de microfinance décide le montant d'un prêt à accorder selon le contexte : historique client, saison (récolte vs creux), volatilité des revenus, type d'activité.

$$x = \pi(c) \in [0, L_{\max}], \quad \mathbb{P}(\text{défaut} \mid c, \pi(c)) \leq \delta,$$

où $\delta \in (0, 1)$ est un seuil de défaut acceptable. On prend

$$\begin{aligned} c &= (\text{revenu, stabilité, saison, activité}) \in \mathcal{C} \\ r &= \text{remboursement effectif} \in \mathbb{R} \\ \Pi &= \left\{ \pi : \mathcal{C} \rightarrow [0, L_{\max}] : \mathbb{P}(\text{défaut} \mid c, \pi(c)) \leq \delta, \forall c \in \mathcal{C} \right\} \end{aligned}$$

L'objectif (profit ajusté du risque) est doc

$$\min_{\pi \in \Pi} \mathbb{E}[-\text{Profit}(\pi(c), r)] \quad \text{ou} \quad \min_{\pi \in \Pi} \mathbb{E}[\text{Perte}(\pi(c), r)].$$

Ces cinq exemples mettent en évidence la structure commune des décisions contextuelles : une décision $\pi(c)$ dépend d'informations observables c et doit être choisie dans un ensemble de politiques Π . Ils constituent un socle direct pour la section suivante, où l'on détaillera l'implémentation : construction d'un échantillon (c_i, r_i) , approximation SAA, choix d'une classe de politiques, et résolution numérique sous contraintes.

3.5 Implémentation et étude empirique

Cette section présente les résultats empiriques obtenus pour les différentes stratégies d'optimisation étudiées dans ce chapitre. Les expériences numériques ont été réalisées à l'aide du notebook `code_chap3.ipynb`. Les données utilisées correspondent aux prix journaliers de cinq grandes actions technologiques américaines : AAPL, MSFT, AMZN, GOOG et META. La période étudiée s'étend du 2 janvier 2015 au 31 décembre 2025, soit un total de 2766 observations.

Les log-rendements sont calculés selon

$$r_{t,i} = \log \left(\frac{P_{t,i}}{P_{t-1,i}} \right),$$

où $P_{t,i}$ désigne le prix de l'actif i au temps t .

3.5.1 Construction du contexte et segmentation en régimes

L'objectif de cette section est d'introduire une information contextuelle permettant de caractériser l'état du marché au cours du temps. Dans cette étude, le contexte est construit à partir d'une mesure de volatilité réalisée du portefeuille de marché.

Soit $r_{m,t}$ le rendement logarithmique du portefeuille de marché à la date t . Ce portefeuille de marché est approché par un portefeuille équipondéré des cinq actifs considérés dans l'étude. La volatilité réalisée est alors définie comme l'écart-type empirique des rendements sur une fenêtre glissante de longueur K :

$$\sigma_t = \sqrt{\frac{1}{K} \sum_{s=t-K}^{t-1} r_{m,s}^2}.$$

Dans l'implémentation numérique, nous retenons une fenêtre

$$K = 20$$

jours de bourse, ce qui correspond approximativement à un mois de données quotidiennes. Autrement dit, la volatilité à la date t est calculée à partir des rendements observés sur les 20 jours précédents, c'est-à-dire sur l'intervalle $\{t-20, \dots, t-1\}$. Cette construction garantit que la variable de contexte repose uniquement sur l'information disponible avant la date t .

La distribution empirique de la volatilité réalisée est ensuite utilisée pour définir différents régimes de marché. Plus précisément, deux seuils correspondant aux quantiles de la distribution de σ_t permettent de segmenter les observations en trois régimes.

Soient

$$q_1 = Q_{33\%}(\sigma_t), \quad q_2 = Q_{66\%}(\sigma_t).$$

La variable de contexte c_t est alors définie par

$$c_t = \begin{cases} 1 & \text{si } \sigma_t \leq q_1, \\ 2 & \text{si } q_1 < \sigma_t \leq q_2, \\ 3 & \text{si } \sigma_t > q_2. \end{cases}$$

Cette classification permet de distinguer trois environnements de marché correspondant respectivement à des périodes de faible, moyenne et forte volatilité.

Dans notre échantillon, les seuils empiriques obtenus sont

$$q_1 = 0.0105, \quad q_2 = 0.0155.$$

La répartition des observations entre les régimes est la suivante :

Régime 1 : 916 observations,

Régime 2 : 915 observations,

Régime 3 : 915 observations.

La quasi-égalité des effectifs confirme que la segmentation par quantiles produit des groupes de taille comparable, ce qui facilite l'estimation des paramètres conditionnels (μ_k, Σ_k) dans chaque régime.

La figure suivante présente l'évolution temporelle de la volatilité réalisée ainsi que les seuils définissant les différents régimes de marché.




FIGURE 3.5.1 – Volatilité réalisée et seuils de régimes utilisés pour définir le contexte de marché.

3.5.2 Comparaison des performances des stratégies

Les performances des différentes stratégies sont résumées dans le tableau suivant.

Portefeuille	Rendement annualisé	Richesse finale
MV statique	0.2375	13.305
CVaR statique	0.2418	13.939
MV contextuel	0.2968	25.378
Équipondéré	0.2235	11.417

TABLE 3.5.1 – Comparaison des performances des différentes stratégies.

Ces résultats montrent clairement l'avantage de la stratégie contextuelle. En particulier :

- * le portefeuille contextuel atteint une richesse finale de 25.38,
- * contre seulement 13.30 pour la stratégie Mean-Variance statique,
- * et 13.94 pour la stratégie CVaR statique.

La stratégie contextuelle génère donc environ

$$\frac{25.38}{13.30} \approx 1.9$$

fois plus de richesse que la stratégie Mean-Variance classique sur la période étudiée.

3.5.3 Trajectoires de richesse réalisées

La figure suivante compare les trajectoires de richesse des différentes stratégies.




FIGURE 3.5.2 – Richesse réalisée des différentes stratégies.

On observe que la stratégie contextuelle domine progressivement les autres stratégies, en particulier à partir de la seconde moitié de la période étudiée.

La figure suivante présente la même comparaison en échelle logarithmique.

sée (échelle log10) — MV statique vs CVaR statique vs MV




FIGURE 3.5.3 – Richesse réalisée en échelle logarithmique.

L'échelle logarithmique met en évidence une croissance plus rapide du portefeuille contextuel, ce qui correspond à un taux de croissance moyen plus élevé.

3.5.4 Influence du paramètre d'aversion au risque

Le paramètre η joue un rôle fondamental dans l'optimisation de portefeuille puisqu'il contrôle le compromis entre rendement et risque.

La figure suivante montre l'évolution du rendement espéré annualisé en fonction de $\log_{10}(\eta)$.




FIGURE 3.5.4 – Rendement espéré annualisé en fonction du paramètre η .

On observe que lorsque η augmente, les portefeuilles deviennent progressivement plus conservateurs, ce qui entraîne une diminution du rendement espéré. La figure suivante présente la richesse attendue à un horizon d'un an.




FIGURE 3.5.5 – Richesse attendue à un an selon η .

La stratégie contextuelle offre une richesse attendue plus élevée pour une large plage de valeurs de η .

3.5.5 Robustesse de la stratégie contextuelle

Afin d'évaluer la robustesse des résultats, la richesse finale est calculée pour 200 valeurs de η comprises entre 0.01 et 100.




FIGURE 3.5.6 – Richesse finale selon le paramètre η .

On observe que la stratégie contextuelle domine les autres stratégies pour une large plage de valeurs du paramètre η . Elle devient légèrement moins performante uniquement lorsque l'aversion au risque devient très élevée.

La figure suivante illustre les trajectoires de richesse pour plusieurs valeurs représentatives du paramètre η .




FIGURE 3.5.7 – Trajectoires de richesse pour différentes valeurs de η .

Ces résultats suggèrent que l'utilisation d'un contexte de marché permet d'adapter dynamiquement l'allocation du portefeuille aux conditions économiques.

3.5.6 Interprétation économique

D'un point de vue économique, ces résultats reflètent l'importance de la prise en compte des régimes de volatilité dans la gestion de portefeuille.

Dans les périodes de faible volatilité, les portefeuilles peuvent adopter des allocations plus agressives afin de capter la croissance des marchés financiers. À l'inverse, lors des périodes de forte volatilité, il devient optimal de réduire l'exposition au risque afin de limiter les pertes potentielles.

La stratégie contextuelle permet précisément d'effectuer cet ajustement dynamique. Elle capture donc mieux les changements structurels du marché.

Ces résultats sont cohérents avec les observations empiriques de la littérature financière, qui montrent que les marchés financiers présentent des phases de volatilité persistantes. Ignorer ces changements de régime peut conduire à des allocations sous-optimales.

Ainsi, l'introduction d'une information contextuelle améliore significativement la performance des portefeuilles et constitue une approche prometteuse pour la gestion dynamique des actifs financiers.

INTÉGRATION D'UN GÉNÉRATEUR DE SCÉNARIOS À L'OPTIMISATION CONTEXTUELLE

Les chapitres précédents ont étudié différents cadres d'optimisation de portefeuille fondés sur des estimations paramétriques des rendements financiers. Le Chapitre 1 a introduit une formulation moyenne-variance pénalisée, le Chapitre 2 a considéré une mesure de risque asymétrique basée sur la CVaR, et le Chapitre 3 a étendu ces approches en intégrant une information contextuelle via des régimes de volatilité du marché.

Dans ces modèles, les décisions d'allocation reposent sur des estimations des moments de la distribution des rendements, supposées représentatives des conditions futures du marché. Cependant, cette hypothèse peut être fragile en présence d'incertitudes structurelles ou de changements de régime non anticipés.

L'objectif de ce chapitre est d'introduire une extension robuste de l'optimisation contextuelle en intégrant un générateur de scénarios de rendements. Plutôt que de s'appuyer uniquement sur les moments estimés de la distribution, l'optimisation est désormais réalisée à partir d'un ensemble de trajectoires simulées conditionnelles aux régimes de volatilité. Cette approche permet d'évaluer la sensibilité des portefeuilles optimaux aux différentes réalisations possibles des rendements.

La structure du problème d'optimisation reste cohérente avec celle des chapitres précédents : il s'agit de déterminer une allocation de portefeuille minimisant un compromis pénalisé entre risque et rendement. La différence essentielle réside dans l'utilisation d'une approximation empirique basée sur des scénarios simulés.

4.1 Formulation du problème sous incertitude de distribution

Dans les chapitres précédents, nous avons étudié un problème d'optimisation de portefeuille de type moyenne-variance, éventuellement enrichi par une dimension contextuelle via la variable de régime c_t . Les paramètres $(\hat{\mu}, \hat{\Sigma})$ étaient estimés à partir des données historiques et insérés directement dans le problème d'optimisation.

Cette approche repose implicitement sur une hypothèse forte : *la distribution future des rendements coïncide avec celle observée dans le passé*. Or, les marchés financiers sont soumis à des ruptures structurelles, à des changements de régimes et à des chocs exogènes imprévisibles. Il est donc nécessaire de reformuler le problème dans un cadre plus général, où l'incertitude porte non seulement sur les réalisations des rendements, mais également sur leur loi de probabilité.

4.1.1 Cadre probabiliste général

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé. On considère un vecteur aléatoire de rendements

$$R = (R_1, \dots, R_N)^\top \in \mathbb{R}^N.$$

Un portefeuille est défini par un vecteur de poids

$$x = (x_1, \dots, x_N)^\top \in \Delta,$$

où Δ désigne l'ensemble admissible des portefeuilles (long-only et entièrement investis)

$$\Delta = \left\{ x \in \mathbb{R}^N : \mathbf{1}^\top x = 1, \quad x \geq 0 \right\}.$$

La richesse à un pas associée au portefeuille x est

$$W_1(x) = 1 + x^\top R.$$

Sur un horizon multipériodique T , en supposant que le portefeuille est rééquilibré à chaque période, la richesse terminale s'écrit

$$W_T(x) = \prod_{t=1}^T (1 + x^\top R_t).$$

Le problème économique fondamental consiste alors à maximiser l'utilité espérée de la richesse terminale

$$\max_{x \in \Delta} \mathbb{E}_{\mathbb{P}} [U(W_T(x))],$$

où U est une fonction d'utilité croissante et concave.

4.1.2 Incertitude sur la distribution et approximation par scénarios

En réalité, la loi $\mathbb{P}$ des rendements futurs est inconnue. Nous ne disposons que d'un échantillon historique

$$\{R^{(t)}\}_{t=1}^T.$$

Le problème devient donc un problème d'optimisation sous incertitude de distribution

$$\max_{x \in \Delta} \mathbb{E}_{\mathbb{P}} [f(R)],$$

où la fonction f dépend du critère retenu. Pour toute fonction mesurable f des rendements, l'espérance sous la loi inconnue $\mathbb{P}$

$$\mathbb{E}_{\mathbb{P}} [f(R)] = \int f(R) d\mathbb{P}(R)$$

est remplacée par une approximation empirique fondée sur un ensemble de scénarios simulés

$$\mathbb{E}_{\mathbb{P}}[f(R)] \approx \frac{1}{M} \sum_{m=1}^M f(R^{(m)}).$$

Cette approximation repose sur la loi des grands nombres : lorsque $M \rightarrow \infty$, la moyenne empirique converge vers l'espérance réelle.

4.1.3 Extension contextuelle

Dans le chapitre précédent, nous avons introduit une variable de contexte

$$c_t \in \{1, 2, 3\},$$

représentant différents régimes de volatilité du marché. Il est alors naturel de considérer des distributions conditionnelles des rendements

$$R_t \mid c_t = k \sim \mathbb{P}_k.$$

Chaque régime possède ainsi ses propres caractéristiques statistiques

$$\mu_k = \mathbb{E}[R_t \mid c_t = k], \quad \Sigma_k = \text{Var}(R_t \mid c_t = k).$$

Les scénarios de rendements sont alors générés conditionnellement au régime observé :

$$R_t^{(m)} \mid c_t \sim \mathbb{P}_{c_t}.$$

Le portefeuille devient dépendant du régime de marché

$$x_t = x(c_t), \quad x(c_t) \in \Delta.$$

La richesse terminale associée au scénario m est donnée par

$$W_T^{(m)}(x) = \prod_{t=1}^T (1 + x(c_t)^\top R_t^{(m)}).$$

4.1.4 Formulation pénalisée sous scénarios

Afin de conserver la logique d'optimisation introduite dans les chapitres précédents, nous considérons une formulation moyenne-variance pénalisée appliquée aux scénarios simulés.

La moyenne empirique des rendements de portefeuille est définie par

$$\hat{\mu}_M(x) = \frac{1}{M} \sum_{m=1}^M \frac{1}{T} \sum_{t=1}^T x(c_t)^\top R_t^{(m)}.$$

La variance empirique correspondante est donnée par

$$\hat{\sigma}_M^2(x) = \frac{1}{M} \sum_{m=1}^M \frac{1}{T} \sum_{t=1}^T \left(x(c_t)^\top R_t^{(m)} - \hat{\mu}_M(x) \right)^2.$$

Le problème d'optimisation contextuelle sous scénarios s'écrit alors

$$(4.1) \quad \min_{x(\cdot)} \quad \eta \hat{\sigma}_M^2(x) - \hat{\mu}_M(x)$$

sous les contraintes

$$x(c_t) \in \Delta, \quad \forall t.$$

Le paramètre $\eta > 0$ joue le même rôle que dans les chapitres précédents : il règle le compromis entre rendement espéré et risque.

4.2 Génération de scénarios de rendements

La formulation introduite à la Section 4.1 repose sur un ensemble fini de scénarios de rendements

$$\{r_t^{(m)}\}_{t=1,\dots,T}^{m=1,\dots,M},$$

où $r_t^{(m)} \in \mathbb{R}^N$ désigne le vecteur de log-rendements simulés des N actifs à la date t dans le scénario m . Il reste donc à préciser comment ces scénarios sont construits.

L'objectif de cette section est de présenter le modèle stochastique utilisé pour générer des trajectoires plausibles de prix et de rendements, tout en restant cohérent avec la structure contextuelle introduite au Chapitre 3. Comme dans les chapitres précédents, l'analyse empirique repose sur les mêmes actifs technologiques et sur les mêmes conventions de calcul des rendements. Le générateur de scénarios constitue ici un prolongement naturel du cadre contextuel : au lieu de s'appuyer sur une unique estimation conditionnelle des moments, on simule explicitement un ensemble de trajectoires possibles conditionnelles aux régimes de marché.

4.2.1 Modèle stochastique des prix

On considère un actif financier dont le prix $S_i(t)$ suit un mouvement brownien géométrique. Pour chaque actif $i \in \{1, \dots, N\}$, la dynamique continue s'écrit

$$\frac{dS_i(t)}{S_i(t)} = \mu_i dt + \sigma_i dW_i(t),$$

où $\mu_i \in \mathbb{R}$ représente le taux de croissance moyen, $\sigma_i > 0$ la volatilité instantanée, et $W_i(t)$ un mouvement brownien standard.

Dans un cadre multi-actifs, les mouvements browniens ne sont pas indépendants : ils sont corrélés afin de reproduire la structure de dépendance observée entre les actifs. On introduit ainsi un vecteur brownien

$$W(t) = (W_1(t), \dots, W_N(t))^T,$$

et une matrice de covariance $\Sigma \in \mathbb{R}^{N \times N}$, symétrique définie positive, décrivant les dépendances entre les chocs aléatoires.

En appliquant la formule d'Itô à $\log S_i(t)$, on obtient

$$d \log S_i(t) = \left(\mu_i - \frac{1}{2} \sigma_i^2 \right) dt + \sigma_i dW_i(t).$$

En écriture vectorielle, la dynamique des log-prix s'écrit donc

$$d \log S(t) = \left(\mu - \frac{1}{2} \text{diag}(\Sigma) \right) dt + \Sigma^{1/2} dB(t),$$

où $B(t)$ est un vecteur brownien standard indépendant, et $\Sigma^{1/2}$ désigne une racine carrée de la matrice Σ (par exemple obtenue par décomposition de Cholesky).

Après discrétisation à pas constant Δt , on obtient la relation

$$\log \left(\frac{S_{t+1}}{S_t} \right) = \left(\mu - \frac{1}{2} \text{diag}(\Sigma) \right) \Delta t + \sqrt{\Delta t} \Sigma^{1/2} Z_t,$$

avec

$$Z_t \sim \mathcal{N}(0, I_N).$$

Autrement dit, le vecteur de log-rendements vérifie

$$r_{t+1} = \log \left(\frac{S_{t+1}}{S_t} \right) = \left(\mu - \frac{1}{2} \text{diag}(\Sigma) \right) \Delta t + \sqrt{\Delta t} \Sigma^{1/2} Z_t,$$

et suit donc une loi normale multivariée.

La dynamique des prix peut alors être reconstruite par

$$S_{t+1} = S_t \odot \exp \left(\left(\mu - \frac{1}{2} \text{diag}(\Sigma) \right) \Delta t + \sqrt{\Delta t} \Sigma^{1/2} Z_t \right),$$

où $\odot$ désigne le produit composante par composante.

4.2.2 Log-rendements, rendements simples et cohérence avec les chapitres précédents

Dans ce chapitre, il est essentiel de distinguer clairement :

- ★ les prix simulés S_t ,
- ★ les log-rendements

$$r_t = \log \left(\frac{S_t}{S_{t-1}} \right),$$

- ★ les rendements simples

$$R_t = \frac{S_t - S_{t-1}}{S_{t-1}} = e^{r_t} - 1.$$

Bien que le générateur soit formulé au niveau des prix, le calibrage statistique du modèle reste fondé sur les log-rendements, de manière cohérente avec les chapitres précédents. Plus précisément :

- les séries historiques sont transformées en log-rendements ;
- les régimes de volatilité sont construits à partir de ces log-rendements ;
- les paramètres (μ_k, Σ_k) sont estimés dans l'espace des log-rendements ;
- les scénarios simulés utilisés dans l'optimisation sont également des scénarios de log-rendements.

Ce choix présente plusieurs avantages. D'une part, les log-rendements sont additifs dans le temps, ce qui facilite l'interprétation dynamique de la richesse. D'autre part, ils sont généralement mieux compatibles avec l'hypothèse de normalité multivariée sous-jacente au générateur gaussien. Enfin, ce choix assure une continuité méthodologique avec le Chapitre 3, où les comparaisons de stratégies et les trajectoires de richesse ont déjà été construites à partir des log-rendements.

Ainsi, dans la suite, même si des prix simulés peuvent être reconstruits à des fins de visualisation, l'objet principal du générateur reste le tenseur des log-rendements simulés

$$\{r_t^{(m)}\}_{t=1,\dots,T}^{m=1,\dots,M}.$$

4.2.3 Dynamique conditionnelle aux régimes de volatilité

L'une des idées centrales du chapitre précédent est que la distribution des rendements dépend du contexte de marché observé. Nous reprenons ici exactement cette logique, mais en l'insérant dans un cadre de simulation.

On considère une variable de régime

$$c_t \in \{1, 2, 3\},$$

où les trois états correspondent respectivement à :

- * un régime de faible volatilité,
- * un régime de volatilité intermédiaire,
- * un régime de forte volatilité.

Conditionnellement au régime $c_t = k$, le vecteur des log-rendements suit une loi normale multivariée de paramètres spécifiques au régime :

$$r_{t+1} \mid c_t = k \sim \mathcal{N}(\mu_k, \Sigma_k),$$

où

$$\mu_k \in \mathbb{R}^N, \quad \Sigma_k \in \mathbb{R}^{N \times N}.$$

Cette écriture constitue l'analogie, dans le cadre du chapitre présent, de la relation conditionnelle introduite au Chapitre 3. Elle exprime que l'état du marché au temps t détermine la loi utilisée pour générer les rendements du pas suivant.

Dans le cadre des scénarios simulés, cette hypothèse se réécrit

$$r_{t+1}^{(m)} \mid c_t \sim \mathbb{P}_{c_t},$$

où $\mathbb{P}_{c_t}$ désigne la loi gaussienne multivariée associée au régime courant.

En pratique, pour chaque date t et pour chaque scénario m , on génère un vecteur gaussien standard

$$Z_t^{(m)} \sim \mathcal{N}(0, I_N),$$

puis on construit le log-rendement simulé par

$$r_{t+1}^{(m)} = \mu_{c_t} + L_{c_t} Z_t^{(m)},$$

où L_{c_t} est une matrice telle que

$$\Sigma_{c_t} = L_{c_t} L_{c_t}^\top.$$

Cette construction permet de faire varier simultanément :

- le niveau moyen des rendements,
- leur volatilité,
- leur structure de corrélation,

en fonction du régime de marché observé.

4.2.4 Données utilisées pour le calibrage

Le générateur de scénarios repose sur les mêmes données historiques que celles utilisées dans les chapitres précédents. L'analyse empirique s'appuie sur le fichier

`prices_tech.csv`,

qui contient les prix ajustés quotidiens des cinq actions technologiques constituant l'univers d'investissement :

AAPL, MSFT, AMZN, GOOG, META.

Ces données couvrent une période d'environ dix ans et permettent d'estimer les moments historiques nécessaires au calibrage des régimes.

Comme dans le Chapitre 3, le contexte de marché n'est pas introduit à partir d'un indice externe ajouté au fichier, mais à partir d'un proxy interne construit sur la base de l'univers d'actifs étudié. Plus précisément, on définit un rendement de marché interne comme la moyenne équipondérée des log-rendements des cinq actifs :

$$r_{m,t} = \frac{1}{N} \sum_{i=1}^N r_t^{(i)}.$$

La volatilité réalisée calculée sur cette série sert ensuite à définir les régimes de marché. Cette construction permet de conserver une cohérence complète avec les données effectivement disponibles et avec l'approche numérique du chapitre précédent.

4.2.5 Procédure de simulation Monte Carlo

Une fois les paramètres conditionnels (μ_k, Σ_k) estimés, la génération des scénarios repose sur une simulation Monte Carlo.

Pour chaque scénario $m \in \{1, \dots, M\}$, la procédure est la suivante :

- (i) on fixe un régime initial c_0 ;
- (ii) on simule ensuite une trajectoire de régimes

$$(c_1^{(m)}, \dots, c_T^{(m)})$$

à l'aide d'une chaîne de Markov calibrée sur les données historiques;

- (iii) à chaque date t , on génère un vecteur gaussien

$$Z_t^{(m)} \sim \mathcal{N}(0, I_N),$$

puis on construit le log-rendement simulé

$$r_{t+1}^{(m)} = \mu_{c_t^{(m)}} + L_{c_t^{(m)}} Z_t^{(m)};$$

(iv) si nécessaire, on reconstruit les prix simulés à partir de la relation

$$S_{t+1}^{(m)} = S_t^{(m)} \odot \exp(r_{t+1}^{(m)}).$$

À l'issue de cette procédure, on obtient un ensemble de trajectoires simulées

$$\{r_t^{(m)}\}_{t=1,\dots,T}^{m=1,\dots,M},$$

que l'on peut regrouper dans un tenseur de dimension

$$N \times T \times M.$$

Cet ensemble constitue une approximation empirique de la distribution future des log-rendements conditionnels au contexte de marché. Il servira de base à la résolution du problème d'optimisation sous scénarios présenté dans la suite du chapitre.

4.2.6 Rôle économique du générateur de scénarios

L'intérêt du générateur de scénarios n'est pas seulement technique. D'un point de vue financier, il permet de dépasser une vision trop ponctuelle de la distribution des rendements. Au lieu de supposer qu'un unique couple (μ_k, Σ_k) résume parfaitement l'avenir du marché dans chaque régime, on produit un ensemble de trajectoires compatibles avec ces paramètres, ce qui permet :

- ★ d'évaluer la dispersion possible des performances futures ;
- ★ de tester la stabilité des décisions optimales ;
- ★ d'analyser la sensibilité des allocations à des réalisations défavorables ;
- ★ de construire une version plus robuste de l'optimisation contextuelle.

Dans le cas particulier d'un univers composé de valeurs technologiques, cet aspect est particulièrement important. Ces actifs sont sensibles à des facteurs macro-financiers tels que les variations de taux d'intérêt, les anticipations de croissance, les chocs d'innovation, ou encore les épisodes de stress global. Le recours à des scénarios conditionnels aux régimes permet ainsi de mieux représenter la diversité des environnements possibles que ne le ferait une estimation conditionnelle unique.

4.3 Optimisation de portefeuille sous scénarios

La section précédente a permis de construire un ensemble de scénarios de log-rendements simulés

$$\{r_t^{(m)}\}_{t=1,\dots,T}^{m=1,\dots,M},$$

qui décrivent différentes trajectoires possibles de l'évolution future des actifs. Ces scénarios constituent une approximation empirique de la distribution conditionnelle des rendements.

L'objectif de cette section est d'introduire le problème d'optimisation de portefeuille dans ce cadre de scénarios. Contrairement au Chapitre 3, où l'optimisation reposait directement sur des estimations conditionnelles des moments, la décision est ici construite à partir d'un ensemble discret de trajectoires simulées.

4.3.1 Cadre de décision

On considère un portefeuille composé de N actifs risqués. Le vecteur des poids du portefeuille est noté

$$w = (w_1, \dots, w_N)^\top.$$

Comme dans les chapitres précédents, on impose les contraintes usuelles :

$$\sum_{i=1}^N w_i = 1, \quad w_i \geq 0.$$

Ces contraintes correspondent à un portefeuille entièrement investi et à l'absence de vente à découvert.

Dans le cadre sous scénarios, chaque scénario m fournit une trajectoire de log-rendements

$$(r_1^{(m)}, \dots, r_T^{(m)}).$$

Le log-rendement du portefeuille au temps t dans le scénario m est alors donné par

$$r_{p,t}^{(m)} = w^\top r_t^{(m)}.$$

La richesse associée au portefeuille évolue donc selon

$$W_{t+1}^{(m)} = W_t^{(m)} \exp(r_{p,t+1}^{(m)}).$$

Dans la pratique, l'optimisation ne porte pas directement sur la richesse mais sur la distribution des rendements du portefeuille induite par les scénarios simulés.

4.3.2 Espérance empirique sous scénarios

Dans ce cadre discret, l'espérance d'une variable aléatoire peut être approximée par une moyenne sur les scénarios. Pour une fonction f , on obtient

$$\mathbb{E}[f(r)] \approx \frac{1}{M} \sum_{m=1}^M f(r^{(m)}).$$

En particulier, l'espérance du rendement du portefeuille s'écrit

$$\hat{\mu}_p = \frac{1}{M} \sum_{m=1}^M w^\top \bar{r}^{(m)},$$

où

$$\bar{r}^{(m)} = \frac{1}{T} \sum_{t=1}^T r_t^{(m)}$$

désigne le rendement moyen dans le scénario m . De même, la variance empirique peut être estimée par

$$\hat{\sigma}_p^2 = \frac{1}{M} \sum_{m=1}^M \left(w^\top \bar{r}^{(m)} - \hat{\mu}_p \right)^2.$$

Ces quantités permettent de construire une approximation empirique des moments du portefeuille à partir des scénarios.

4.3.3 Formulation moyenne–variance sous scénarios

Comme dans le Chapitre 3, on adopte une formulation pénalisée de type moyenne–variance. Le problème d’optimisation s’écrit

$$\min_w \quad \eta \hat{\sigma}_p^2 - \hat{\mu}_p$$

sous les contraintes

$$\sum_{i=1}^N w_i = 1, \quad w_i \geq 0.$$

Le paramètre $\eta > 0$ représente l’aversion au risque. Lorsque η est faible, l’investisseur privilégie davantage le rendement espéré. À l’inverse, lorsque η est élevé, la variance du portefeuille est plus fortement pénalisée.

Cette formulation présente plusieurs avantages :

- elle conduit à un problème quadratique convexe;
- elle est directement comparable avec les stratégies du Chapitre 3;
- elle permet d’analyser la sensibilité des allocations au paramètre η .

4.3.4 Stratégie contextuelle sous scénarios

Dans la continuité du Chapitre 3, l’optimisation peut également être rendue dépendante du contexte de volatilité.

On introduit une famille de vecteurs de poids

$$w^{(1)}, \quad w^{(2)}, \quad w^{(3)},$$

correspondant respectivement aux régimes

$$c_t = 1, \quad c_t = 2, \quad c_t = 3.$$

Pour un régime donné k , le problème d’optimisation s’écrit

$$\min_{w^{(k)}} \quad \eta \hat{\sigma}_p^{2,(k)} - \hat{\mu}_p^{(k)}$$

où les moments sont calculés uniquement à partir des scénarios correspondant à ce régime.

La politique d’allocation devient donc

$$w_t = w^{(c_t)}.$$

Autrement dit, la composition du portefeuille s’adapte dynamiquement à l’état du marché.

4.4 Implémentation

4.4.1 Calibrage du générateur et simulation des scénarios

La première étape de l'implémentation a été réalisée dans le notebook `code_chap4_generation_scenarios.ipynb`. Ce notebook constitue le point de départ opérationnel du chapitre 4, car il permet de passer d'une représentation contextuelle paramétrique des rendements à une représentation empirique fondée sur un ensemble de scénarios simulés.

Comme dans les chapitres précédents, l'analyse repose sur le fichier `prices_tech.csv`, contenant les prix quotidiens des cinq actifs

AAPL, MSFT, AMZN, GOOG, META.

Les log-rendements sont d'abord calculés à partir de ces prix, puis le contexte de volatilité et les régimes de marché sont reconstruits selon la même logique que dans le chapitre 3. Nous ne revenons donc pas ici sur le détail de cette construction; nous utilisons directement cette segmentation comme base du calibrage du générateur.

4.4.1.1 Estimation des paramètres conditionnels par régime

Pour chaque régime $k \in \{1, 2, 3\}$, le notebook estime la moyenne empirique conditionnelle des log-rendements,

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{t:c_t=k} r_t,$$

ainsi que la matrice de covariance conditionnelle

$$\hat{\Sigma}_k = \frac{1}{n_k - 1} \sum_{t:c_t=k} (r_t - \hat{\mu}_k)(r_t - \hat{\mu}_k)^\top.$$

Les moyennes estimées sont résumées dans le tableau suivant.

Actif	$\hat{\mu}_1$	$\hat{\mu}_2$	$\hat{\mu}_3$
AAPL	0.00135821	0.000242355	0.000964163
MSFT	0.00132458	0.000437542	0.00111590
AMZN	0.00131028	0.000749004	0.000744284
GOOG	0.00104323	0.00108220	0.000565364
META	0.000973956	0.000255815	0.00113291

TABLE 4.4.1 – Moyennes conditionnelles estimées des log-rendements par régime.

Ces valeurs montrent que les profils de rendement moyen changent selon le régime. Autrement dit, la rentabilité conditionnelle d'un actif n'est pas stable lorsque l'environnement de marché évolue. Cette hétérogénéité justifie le passage à une modélisation conditionnelle : une allocation optimale construite sur une moyenne

unique risquerait de masquer des différences importantes entre périodes calmes et périodes turbulentes.

Les variances diagonales estimées sont données par :

Actif	$\text{diag}(\hat{\Sigma}_1)$	$\text{diag}(\hat{\Sigma}_2)$	$\text{diag}(\hat{\Sigma}_3)$
AAPL	0.000151061	0.000230303	0.000602186
MSFT	0.0000935607	0.000219307	0.000534950
AMZN	0.000151040	0.000338649	0.000777061
GOOG	0.000130270	0.000305795	0.000549229
META	0.000182739	0.000354119	0.001175620

TABLE 4.4.2 – Variances conditionnelles estimées des log-rendements par régime.

Le résultat essentiel est ici l'augmentation marquée du risque lorsque l'on passe du régime 1 au régime 3. Cette hiérarchie est vérifiée pour tous les actifs, ce qui confirme que la segmentation précédente est économiquement pertinente. On observe également que certains titres, en particulier META et AMZN, deviennent sensiblement plus risqués dans les régimes de forte volatilité. Cela renforce l'idée que la structure de dépendance au régime doit être intégrée dès la génération des scénarios, et non seulement au moment de l'optimisation.

4.4.1.2 Estimation de la dynamique des régimes

Le notebook estime ensuite une matrice de transition empirique pour la chaîne de Markov gouvernant les régimes :

$$P = \begin{pmatrix} 0.942077 & 0.0568306 & 0.0010929 \\ 0.0579235 & 0.907104 & 0.0349727 \\ 0.0010929 & 0.0360656 & 0.962842 \end{pmatrix}.$$

Cette matrice est fortement diagonale, ce qui signifie que les régimes sont persistants : un marché déjà calme a une forte probabilité de rester calme au pas suivant, et un marché déjà turbulent a également tendance à demeurer turbulent. Par ailleurs, les transitions directes entre régimes extrêmes restent très rares. Le passage d'un état calme à un état de stress se fait donc le plus souvent par l'intermédiaire du régime moyen.

Cette propriété est importante du point de vue financier. Elle signifie que le générateur ne produit pas des successions erratiques de régimes sans mémoire, mais une dynamique temporelle cohérente avec les comportements observés sur les marchés : les phases de tension et de détente ont une certaine inertie.

4.4.1.3 Décomposition de Cholesky et simulation Monte Carlo

Pour chaque régime, une décomposition de Cholesky est calculée à partir de $\hat{\Sigma}_k$. Cette étape permet de simuler, à partir de vecteurs gaussiens standards indépendants, des chocs corrélés respectant la structure de covariance estimée. Le notebook génère ensuite

5000

scénarios, chacun sur un horizon de

252

jours de bourse. Un scénario individuel contient donc une matrice de dimension

(252, 5)

de log-rendements simulés, ainsi que la matrice correspondante de rendements simples.

Les statistiques globales des log-rendements simulés sont résumées dans le tableau suivant.

Actif	Moyenne simulée	Variance simulée
AAPL	0.000867187	0.000317636
MSFT	0.000935925	0.000273601
AMZN	0.000935411	0.000409733
GOOG	0.000904811	0.000320951
META	0.000782966	0.000548691

TABLE 4.4.3 – Statistiques empiriques des log-rendements simulés.

Ces résultats sont cohérents avec les ordres de grandeur obtenus lors du calibrage conditionnel. Les moyennes simulées restent positives pour tous les actifs, tandis que les variances conservent la hiérarchie observée dans les données historiques, avec un niveau de risque particulièrement élevé pour META. Le générateur reproduit donc de manière crédible les propriétés statistiques principales du marché étudié, tout en introduisant la variabilité indispensable à une analyse de robustesse.

4.4.1.4 Analyse des trajectoires simulées

La Figure 4.4.1 représente, pour un scénario donné, l'évolution simulée des prix normalisés des cinq actifs.




FIGURE 4.4.1 – Trajectoire simulée des prix des cinq actifs dans un scénario unique.

Cette figure montre clairement que, même dans un même environnement simulé, les actifs ne suivent pas une trajectoire identique. Les écarts se creusent progressivement, ce qui traduit l'effet cumulé des chocs aléatoires, des corrélations croisées et des changements de régime. GOOG et AMZN apparaissent ici plus dynamiques sur l'horizon simulé, tandis que META suit une trajectoire nettement moins favorable. Cette diversité de comportements est précisément ce que l'on cherche à obtenir : *le générateur doit produire des situations où le choix de portefeuille reste réellement discriminant*.

La Figure 4.4.2 présente plusieurs trajectoires simulées pour un même actif, ici AAPL.




FIGURE 4.4.2 – Trajectoires simulées multiples pour l'actif AAPL.

Cette figure met en évidence la dispersion croissante des trajectoires lorsque l'horizon s'allonge. À partir d'un même calibrage, on obtient des scénarios très différents : certains sont franchement favorables, d'autres beaucoup plus défensifs, voire défavorables. Cette dispersion matérialise concrètement l'incertitude de distribution évoquée dans la partie théorique. Elle montre aussi pourquoi une optimisation fondée sur une estimation unique des moments peut être fragile : deux trajectoires plausibles d'un même actif peuvent conduire à des conclusions très différentes en matière d'allocation.

Du point de vue économique et financier, cette diversité est particulièrement importante dans un univers composé de grandes valeurs technologiques. Ces titres sont fortement sensibles aux annonces macroéconomiques, aux variations de taux, aux révisions d'anticipations de croissance et aux épisodes de stress global. Un générateur de scénarios crédible doit donc être capable de produire non seulement une trajectoire moyenne, mais une famille de trajectoires compatibles avec ces multiples sources d'incertitude.

4.4.2 Optimisation de portefeuille sous scénarios simulés

Cette sous-section présente les résultats obtenus à partir du notebook `chap4_portfolio_optimization_scenarios.ipynb`. Ce notebook constitue le cœur empirique du chapitre 4. Son rôle est double : d'une part, il permet de comparer les stratégies classiques déjà étudiées dans les chapitres précédents avec une stratégie robuste fondée sur les scénarios simulés ; d'autre part, il permet d'évaluer la sensibilité des résultats à plusieurs paramètres essentiels du modèle, en particulier le coefficient de pénalisation η , la fenêtre de volatilité K et le nombre de scénarios M .

4.4.2.1 Chargement des objets issus du notebook 1 et reconstruction du contexte historique

Le notebook commence par charger le fichier `chap4_scenarios_data.jld2` produit par le premier notebook. Ce fichier contient notamment les quantités calibrées par régime (μ_k, Σ_k) , les facteurs de Cholesky, la matrice de transition P , les trajectoires de régimes simulés, ainsi que les scénarios de log-rendements et de rendements simples.

Les informations chargées montrent que l'univers d'investissement comporte

$$N = 5$$

actifs et que le générateur de scénarios a produit

$$M = 5000$$

scénarios sur un horizon de

$$T = 252$$

jours, soit approximativement une année de bourse.

Le fichier `prices_tech.csv` est ensuite rechargé afin de reconstruire le contexte historique utilisé pour évaluer les stratégies sur les données observées. Après calcul des rendements simples et logarithmiques, on obtient

$$2765$$

observations de rendements pour chacun des cinq actifs.

Comme dans le chapitre 3, le contexte de volatilité est reconstruit à partir d'une fenêtre glissante de taille

$$K = 20.$$

Après suppression des premières observations incomplètes, le nombre de dates effectivement retenues est

$$2746.$$

La répartition historique entre régimes est la suivante :

$$\text{régime 1 : 916,} \quad \text{régime 2 : 915,} \quad \text{régime 3 : 915.}$$

Cette quasi-symétrie confirme que la discrétisation par terciles reste bien équilibrée et permet une comparaison stable entre les stratégies conditionnelles.

4.4.2.2 Résolution sur la grille de pénalisation η

Le notebook résout ensuite, pour une grille de 200 valeurs de η comprise entre 10^{-2} et 10^2 , les stratégies suivantes :

- ★ le portefeuille équipondéré;
- ★ la stratégie moyenne-variance statique;
- ★ la stratégie CVaR pénalisée;
- ★ la stratégie contextuelle simple fondée sur les régimes historiques;
- ★ la stratégie robuste sous-scénarios.

Pour chaque valeur de η , le notebook calcule les rendements annualisés et les richesses finales associées à ces différentes approches. Un extrait des résultats obtenus est donné dans le tableau 4.4.4.

η	$\log_{10}(\eta)$	$ER_{ann,ctx}$	$ER_{ann,scen}$	W_{ctx}	W_{scen}	W_{EW}
0.01	-2.0000	0.300175	0.297347	26.3363	25.5373	11.4166
0.014678	-1.8333	0.299984	0.297347	26.2818	25.5374	11.4166
0.021544	-1.6667	0.299611	0.297347	26.1751	25.5373	11.4166
0.031623	-1.5000	0.299356	0.297347	26.1026	25.5373	11.4166
0.046416	-1.3333	0.299183	0.297347	26.0534	25.5374	11.4166
0.068129	-1.1667	0.299065	0.297347	26.0198	25.5373	11.4166
0.100000	-1.0000	0.298985	0.297133	25.9970	25.4778	11.4166
0.146780	-0.8333	0.298930	0.296925	25.9815	25.4200	11.4166
0.215443	-0.6667	0.298422	0.296897	25.8383	25.4124	11.4166
0.316228	-0.5000	0.297921	0.296879	25.6975	25.4073	11.4166

TABLE 4.4.4 – Extrait des résultats obtenus sur la grille des valeurs de η .

Ce premier tableau met déjà en évidence un résultat important : pour les faibles valeurs de η , les approches contextuelle et sous-scénarios dominent très largement les stratégies de référence. La richesse finale est alors supérieure à 25, contre seulement 11.42 pour le portefeuille équipondéré et environ 13.94 pour les approches statiques optimisées. Autrement dit, lorsque la pénalisation du risque reste modérée, l'exploitation de l'information contextuelle et des scénarios simulés procure un gain très substantiel.

4.4.2.3 Comparaison détaillée des stratégies pour $\eta = 1$

Afin d'obtenir une comparaison lisible entre les différentes stratégies, le notebook retient ensuite la valeur

$$\eta_{\text{plot}} = 1.$$

Pour cette valeur, les richesses finales observées sont résumés dans le tableau 4.4.5.

Stratégie	ER_ann	Sharpe	MaxDD	Richesse finale
Équipondéré	0.223466	0.870141	-0.482491	11.4166
MV statique	0.237336	0.939550	-0.388392	13.2793
CVaR	0.241787	0.906240	-0.371482	13.9393
Contextuel	0.296660	1.071520	-0.402337	25.3467
Sous-scénarios	0.295161	1.070100	-0.439857	24.9361

TABLE 4.4.5 – Comparaison des performances des différentes stratégies pour $\eta = 1$.

Ce tableau est particulièrement important pour l'interprétation économique des résultats.

Premièrement, le portefeuille équi pondéré constitue une référence naïve mais utile. Sa richesse finale de 11.4166 montre qu'un simple partage uniforme du capital sur les cinq actifs permet déjà une croissance positive du portefeuille, mais reste nettement sous-optimal.

Deuxièmement, la stratégie moyenne-variance statique améliore cette base de référence, ce qui confirme que l'optimisation paramétrique classique apporte un gain de performance. Cependant, ce gain reste limité : la richesse finale n'atteint que 13.2793.

Troisièmement, la stratégie CVaR améliore encore légèrement la stratégie statique, avec une richesse finale de 13.9393. Cela suggère qu'une prise en compte asymétrique du risque extrême est utile, mais demeure insuffisante pour capturer la complexité des changements de régime.

Quatrièmement, les deux approches dépendantes du contexte dominent nettement toutes les autres. La stratégie contextuelle simple atteint une richesse finale de 25.3467, tandis que la stratégie robuste sous-scénarios atteint 24.9361. En termes économiques, cela signifie que la prise en compte explicite de la dynamique de volatilité et de l'incertitude distributionnelle permet pratiquement de doubler la richesse terminale par rapport aux méthodes statiques.

Enfin, les ratios de Sharpe des stratégies contextuelle (1.0715) et sous-scénarios (1.0701) sont également les meilleurs du tableau. Le gain obtenu n'est donc pas seulement un gain brut de richesse ; il correspond aussi à une amélioration du couple rendement-risque. Autrement dit, la supériorité de ces méthodes n'est pas due à une simple prise de risque excessive, mais à une allocation plus efficace.

4.4.2.4 Comparaison des trajectoires de richesse

La figure 4.4.3 représente les trajectoires de richesse historique des cinq stratégies pour $\eta = 1$.




FIGURE 4.4.3 – Richesse réalisée – comparaison des stratégies.

Cette figure confirme visuellement la hiérarchie observée dans le tableau précédent. La courbe équipondérée reste en permanence en dessous des autres méthodes, ce qui traduit la sous-optimalité d'une allocation uniforme dans un univers de valeurs technologiques hétérogènes. Les courbes moyenne-variance et CVaR restent relativement proches l'une de l'autre, avec un léger avantage à la stratégie CVaR sur une grande partie de l'échantillon.

Les stratégies contextuelle et sous-scénarios se distinguent nettement. Elles décollent progressivement des autres méthodes à mesure que le temps avance, ce qui suggère que leur avantage se construit dans la durée. Ce point est important : la supériorité ne provient pas d'un épisode isolé, mais d'une capacité répétée à mieux s'adapter aux conditions de marché.

Sur le plan économique, cette performance peut s'expliquer par la nature même des actifs étudiés. Les valeurs technologiques sont fortement sensibles aux variations des taux d'intérêt, aux anticipations de croissance, aux chocs macroéconomiques et aux épisodes de stress de marché. Dans un tel univers, une stratégie figée devient rapidement inadéquate. À l'inverse, une stratégie conditionnée aux régimes ou fondée sur des scénarios simulés est naturellement mieux armée pour absorber les transitions entre phases calmes et turbulentes.

4.4.2.5 Analyse de la richesse finale en fonction de η

La figure 4.4.4 présente l'évolution de la richesse finale de chaque stratégie en fonction de $\log_{10}(\eta)$.




FIGURE 4.4.4 – Richesse finale selon η .

Cette figure synthétise un phénomène central du chapitre. Pour les faibles valeurs de η , les stratégies contextuelle et sous-scénarios sont très largement dominantes. Lorsque η augmente, leurs richesses finales diminuent fortement, jusqu'à

devenir proches, voire inférieures, à celles des approches statiques pour les plus fortes pénalisations.

Cette décroissance s'interprète naturellement. Un η faible laisse davantage de place à la recherche de rendement. Dans ce cas, l'information contextuelle et les scénarios simulés sont pleinement exploités pour concentrer les portefeuilles sur les états de marché jugés les plus favorables. À l'inverse, lorsque η devient élevé, la pénalisation du risque domine et toutes les stratégies tendent vers des allocations beaucoup plus prudentes. L'avantage informationnel du contexte ou des scénarios devient alors moins visible.

On retrouve ici une idée économique intuitive : les approches riches en information sont particulièrement utiles lorsque l'investisseur accepte un certain niveau de risque pour capter les opportunités de marché. Lorsque la prudence devient extrême, les stratégies convergent naturellement vers des comportements proches.

4.4.2.6 Figures multi-trajectoires pour différentes valeurs de η

Afin de visualiser concrètement l'effet du paramètre η sur les trajectoires de richesse, le notebook produit la figure 4.4.5.




FIGURE 4.4.5 – Trajectoires de richesse pour différentes valeurs de η .

Cette figure permet de suivre simultanément l'évolution des cinq stratégies pour

$$\eta \in \{0.01, 0.05, 0.1, 0.5, 1.0, 5.0\}.$$

Pour $\eta = 0.01$, $\eta = 0.05$ et $\eta = 0.1$, les courbes contextuelle et sous-scénarios se situent très nettement au-dessus des autres. La méthode robuste sous-scénarios suit alors de très près la stratégie contextuelle simple, ce qui montre que les scénarios simulés reproduisent correctement l'information structurelle contenue dans les régimes historiques.

Pour $\eta = 0.5$ et $\eta = 1.0$, la hiérarchie demeure la même, mais l'écart avec les stratégies statiques commence à se réduire légèrement. Enfin, pour $\eta = 5.0$, toutes les trajectoires deviennent beaucoup plus rapprochées et les gains des stratégies conditionnelles diminuent sensiblement.

Cette lecture visuelle complète utilement la figure précédente. Elle montre que la sensibilité à η ne porte pas seulement sur la richesse terminale, mais également sur la forme complète de la trajectoire. Autrement dit, le paramètre η modifie non seulement le niveau final de performance, mais aussi la manière dont cette performance s'accumule dans le temps.

Tableau de sensibilité à η

Les résultats numériques détaillés associés à l'analyse de sensibilité en η sont présentés dans le tableau 4.4.6.

η	W_{EW}	W_{MV}	W_{CVaR}	W_{ctx}	W_{scen}	S_{EW}	S_{MV}	S_{CVaR}	S_{ctx}	S_{scen}
0.01	11.4166	13.9393	13.9393	26.3363	26.3363	0.8701	0.9062	0.9062	0.8110	0.8110
0.05	11.4166	13.9393	13.9393	26.0458	26.2007	0.8701	0.9062	0.9062	1.0169	0.9204
0.10	11.4166	13.9393	13.9393	25.9970	26.0742	0.8701	0.9062	0.9062	1.0318	1.0040
0.50	11.4166	13.8321	13.9393	25.5858	25.7268	0.8701	0.9179	0.9062	1.0668	1.0580
1.00	11.4166	13.2793	13.9393	25.3467	25.2563	0.8701	0.9396	0.9062	1.0715	1.0714
5.00	11.4166	12.4282	13.4499	17.0963	16.9062	0.8701	0.9428	0.9317	1.0360	1.0335

TABLE 4.4.6 – Analyse de sensibilité à η .

Le tableau montre que les stratégies robustes demeurent supérieures sur une plage assez large de valeurs de η . Même pour $\eta = 5$, elles restent au-dessus de la stratégie équipondérée et de la stratégie moyenne-variance statique. La domination est donc robuste, même si son ampleur diminue avec la pénalisation.

Il est également intéressant de noter que, pour $\eta = 1$, la stratégie contextuelle simple surperforme très légèrement la stratégie sous-scénarios en richesse finale. Cela indique que les scénarios simulés ne dominent pas nécessairement la stratégie contextuelle historique pour toutes les valeurs du paramètre. En revanche, ils produisent une performance très proche, ce qui confirme la pertinence du générateur de scénarios.

4.4.2.7 Sensibilité à la fenêtre de volatilité K

Le notebook étudie ensuite l'effet de la taille de la fenêtre de volatilité utilisée pour construire les régimes de marché. Les valeurs considérées sont :

$$K \in \{10, 15, 20, 25, 30, 40\}.$$

Les résultats numériques sont donnés dans le tableau 4.4.7.

K	W_{ctx}	S_{ctx}
10	19.6834	1.01262
15	29.6515	1.09370
20	25.3467	1.07152
25	18.0512	0.975011
30	19.9400	1.01199
40	22.1836	1.00174

TABLE 4.4.7 – Analyse de sensibilité à la fenêtre de volatilité K .

La figure 4.4.6 illustre ces résultats.




FIGURE 4.4.6 – Sensibilité à la fenêtre de volatilité.

On observe que la meilleure performance est obtenue pour

$$K = 15,$$

avec une richesse finale de 29.6515, supérieure à celle obtenue pour la valeur de référence $K = 20$.

Ce résultat est intéressant sur le plan économique. Une fenêtre de volatilité trop courte peut produire des régimes instables, trop sensibles aux chocs de court terme. À l'inverse, une fenêtre trop longue lisse excessivement l'information et retarde la

détection des changements de régime. Le cas $K = 15$ semble ici fournir le meilleur compromis entre réactivité et stabilité.

La figure multi-trajectoires correspondante est donnée par la figure 4.4.7.




FIGURE 4.4.7 – Trajectoires de richesse pour différentes valeurs de la fenêtre K .

Cette figure montre que la performance de la stratégie contextuelle est très sensible au choix de K . Lorsque $K = 15$, la courbe contextuelle domine nettement toutes les autres sur presque tout l'échantillon. En revanche, pour $K = 25$, la performance chute fortement. Cela confirme que la construction du contexte est un élément central du modèle. En pratique, le choix de K ne doit donc pas être arbitraire ; il doit être calibré avec soin.

4.4.2.8 Sensibilité au nombre de scénarios M

Le notebook évalue également l'effet du nombre de scénarios simulés sur la stratégie robuste sous-scénarios. Les valeurs testées sont

$$M \in \{500, 1000, 2000, 3000, 4000, 5000\}.$$

Les résultats sont reportés dans le tableau 4.4.8.

M	W_{scen}	S_{scen}
500	24.9290	1.06915
1000	25.0592	1.07080
2000	25.3034	1.07092
3000	25.2164	1.07172
4000	25.2232	1.07026
5000	25.2563	1.07138

TABLE 4.4.8 – Analyse de sensibilité au nombre de scénarios M .

La figure 4.4.8 en donne une représentation graphique.




FIGURE 4.4.8 – Sensibilité au nombre de scénarios.

On constate que la richesse finale augmente légèrement entre $M = 500$ et $M = 2000$, puis se stabilise autour de 25.2 à 25.3. Le ratio de Sharpe reste également extrêmement stable, autour de 1.07.

Ce résultat est très favorable à l'approche proposée. Il signifie que la stratégie robuste sous-scénarios ne dépend pas de manière excessive du nombre de trajectoires simulées, dès lors que ce nombre est suffisamment grand. En pratique, cela implique qu'un niveau intermédiaire de simulation, par exemple $M = 2000$ ou $M = 3000$, peut déjà suffire pour produire des décisions stables, sans alourdir inutilement le coût numérique.

La figure multi-trajectoires correspondante est donnée par la figure 4.4.9.




FIGURE 4.4.9 – Trajectoires de richesse pour différentes valeurs de M .

Visuellement, les trajectoires restent très proches lorsque M varie. Cela confirme que la stratégie robuste est numériquement stable vis-à-vis du nombre de scénarios. Cette stabilité constitue un argument important en faveur de la robustesse pratique de l'approche.

4.4.2.9 Lecture croisée des résultats

Pris ensemble, les tableaux et figures précédents permettent de dégager trois enseignements majeurs.

Premièrement, l'introduction de l'information contextuelle améliore fortement les performances par rapport aux stratégies statiques. Cela confirme l'idée déjà mise en évidence au chapitre 3 : les régimes de volatilité contiennent une information prédictive utile pour l'allocation de portefeuille.

Deuxièmement, l'approche robuste sous-scénarios parvient à reproduire presque intégralement la performance de la stratégie contextuelle simple. Cela signifie que le générateur de scénarios calibré dans le notebook `code_chap4_generation_scenarios.ipynb` est suffisamment pertinent pour transmettre l'essentiel de l'information utile à la décision.

Troisièmement, les tests de sensibilité montrent que la méthode reste globalement robuste. La performance varie avec η , K et M , mais la domination des straté-

gies conditionnelles demeure sur une plage large de paramètres. Autrement dit, les résultats ne reposent pas sur un réglage artificiellement favorable d'un seul paramètre.

4.4.2.10 Interprétation économique et financière

D'un point de vue économique, ces résultats sont cohérents avec la nature des actifs considérés. Les cinq actions étudiées appartiennent au secteur technologique, un secteur notoirement sensible :

- aux variations des taux directeurs ;
- aux anticipations de croissance ;
- aux révisions de bénéfices ;
- aux chocs géopolitiques ;
- aux épisodes de stress systémique.

Dans un tel environnement, une stratégie statique souffre inévitablement d'un défaut d'adaptation. À l'inverse, une stratégie conditionnée aux régimes de volatilité peut modifier son exposition lorsque le marché devient plus instable. La version robuste sous-scénarios ajoute à cela une prise en compte explicite de l'incertitude sur la distribution future des rendements.

Sur le plan financier, cela revient à dire que l'investisseur ne se contente plus d'une estimation unique des moments du marché ; il internalise un éventail de trajectoires plausibles. Cette diversification des futurs possibles renforce la robustesse de la décision et limite la dépendance à une seule spécification paramétrique.

Sur le plan macro-financier enfin, les résultats observés illustrent bien le fait que les marchés ne sont pas homogènes dans le temps. Les périodes de faible volatilité, de volatilité modérée et de forte turbulence n'offrent pas les mêmes opportunités ni les mêmes risques. Un modèle capable de s'adapter à cette hétérogénéité a donc naturellement un avantage sur les approches purement statiques.

Conclusion et Perspectives

Ce mémoire a proposé une approche originale pour l'optimisation de portefeuille en intégrant explicitement l'incertitude des marchés financiers à travers un générateur de scénarios dépendant du contexte. L'objectif principal était de dépasser les limites des modèles classiques, notamment l'hypothèse de stationnarité, en introduisant une dynamique adaptative fondée sur des régimes de volatilité.

Dans un premier temps, un cadre théorique basé sur l'optimisation moyenne-variance pénalisée a été présenté, puis enrichi par l'introduction d'une information de contexte permettant d'adapter dynamiquement les décisions d'allocation. Cette approche a ensuite été étendue par la construction d'un générateur de scénarios reposant sur une modélisation en régimes, combinant chaînes de Markov et dynamiques de type GBM.

L'ensemble de ces éléments a conduit à la définition d'une stratégie d'optimisation contextuelle robuste, capable d'exploiter l'information sur l'état du marché tout en intégrant l'incertitude future à travers un ensemble de trajectoires simulées.

Les résultats empiriques obtenus sur des données réelles ont permis de mettre en évidence plusieurs faits marquants. Tout d'abord, les stratégies intégrant le contexte surpassent systématiquement les approches classiques, tant en termes de richesse finale que de performance ajustée du risque. Ensuite, l'introduction des sous-scénarios permet d'améliorer encore la robustesse des allocations, en capturant plus finement la variabilité des rendements futurs. Enfin, l'analyse de sensibilité a montré que la performance du modèle dépend de manière significative du paramètre d'aversion au risque, ainsi que des choix liés à la construction du contexte et du nombre de scénarios.

Ces résultats confirment l'intérêt d'une approche combinant information contextuelle et simulation de scénarios pour la gestion de portefeuille. Ils montrent également que la prise en compte de la non-stationnarité des marchés constitue un levier essentiel pour améliorer les performances.

Du point de vue des perspectives, plusieurs extensions naturelles peuvent être envisagées afin d'enrichir le modèle proposé.

Une première piste consisterait à intégrer explicitement des coûts de transaction, afin de tenir compte du coût réel des réallocations dynamiques entre deux dates successives. Dans ce cas, le problème d'optimisation pourrait être reformulé sous la forme

$$\max_{w_t} \quad \eta \hat{\sigma}_t^2 - \hat{\mu}_t - \lambda \|w_t - w_{t-1}\|_1,$$

où w_t désigne le vecteur des poids du portefeuille à la date t , w_{t-1} celui de la période précédente, $\hat{\mu}_t$ le rendement espéré conditionnel du portefeuille, $\hat{\sigma}_t^2$ sa variance

conditionnelle, $\eta > 0$ le coefficient d'aversion au risque, et $\lambda > 0$ un paramètre représentant l'intensité des coûts de transaction. Le terme

$$\|w_t - w_{t-1}\|_1 = \sum_{i=1}^N |w_t^i - w_{t-1}^i|$$

mesure le volume total de réallocation entre les actifs. Ainsi, plus le portefeuille est modifié d'une période à l'autre, plus le coût associé est élevé. Cette extension permettrait de rapprocher le modèle des conditions réelles de marché, dans lesquelles toute réallocation importante entraîne des frais de courtage, des coûts de liquidité ou encore des effets de spread.

Une deuxième extension porterait sur l'amélioration du générateur de scénarios, en remplaçant la dynamique de type GBM par des modèles plus réalistes intégrant une volatilité stochastique :

$$dS_t = \mu S_t dt + \sigma_t S_t dW_t,$$

ce qui permettrait de mieux capturer les phénomènes de clustering de volatilité observés sur les marchés financiers.

Par ailleurs, l'introduction de mesures de risque alternatives, telles que la Value-at-Risk ou la Conditional Value-at-Risk, dans un cadre dynamique dépendant du contexte, constitue une piste prometteuse. On pourrait notamment envisager l'optimisation directe d'une quantité du type :

$$\min_w \text{CVaR}_\alpha(R_p),$$

afin de contrôler explicitement les pertes extrêmes.

Enfin, une extension naturelle consisterait à intégrer des techniques d'apprentissage automatique pour la détection des régimes, en remplaçant les seuils fixes par des modèles appris à partir des données. Cela permettrait de rendre le modèle encore plus adaptatif et performant dans des environnements complexes.

En conclusion, ce travail met en évidence le potentiel des approches hybrides combinant modélisation stochastique, information contextuelle et simulation de scénarios. Il ouvre la voie à de nombreuses extensions, tant théoriques qu'appliquées, pour une gestion de portefeuille plus robuste, plus flexible et mieux adaptée aux réalités des marchés financiers.

Bibliographie

Références théoriques

- [1] A. Ang and G. Bekaert, International Asset Allocation with Regime Shifts, *Review of Financial Studies*, Vol. 15, No. 4, pp. 1137–1187, 2002.
- [2] P. Artzner, F. Delbaen, J.-M. Eber, D. Heath, *Coherent Measures of Risk*, *Mathematical Finance*, 9(3), pp. 203–228, 1999.
- [3] A. Ben-Tal, L. El Ghaoui, A. Nemirovski. *Robust Optimization*. Princeton University Press, 2009.
- [4] J. D. Hamilton, A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle, *Econometrica*, Vol. 57, No. 2, pp. 357–384, 1989.
- [5] D. G. Luenberger, *Investment Science*, Oxford University Press, 1998.
- [6] H. Markowitz, Portfolio Selection, *The Journal of Finance*, Vol. 7, No. 1, pp. 77–91, 1952.
- [7] H. Markowitz, *Portfolio Selection : Efficient Diversification of Investments*, John Wiley & Sons, 1959.
- [8] R. C. Merton, *An Analytic Derivation of the Efficient Portfolio Frontier*, *Journal of Financial and Quantitative Analysis*, 7(4), pp. 1851–1872, 1972.
- [9] R. T. Rockafellar, S. Uryasev, Conditional Value-at-Risk for General Loss Distributions, *Journal of Banking & Finance*, vol. 26, pp. 1443–1471, 2002.
- [10] R. T. Rockafellar, S. Uryasev, *Optimization of Conditional Value-at-Risk*, *Journal of Risk*, 2(3), pp. 21–42, 2000.
- [11] A. Shapiro, D. Dentcheva, A. Ruszczyński, *Lectures on Stochastic Programming*, SIAM, 2009.

Références bibliographiques liées au code

- [12] CSV.jl Documentation. <https://csv.julidata.org/stable/>
- [13] DataFrames.jl Documentation. <https://dataframes.julidata.org/stable/>
- [14] Gurobi Optimization, LLC, *Gurobi Optimizer Reference Manual*, <https://www.gurobi.com/documentation/>
- [15] HTTP.jl Documentation. <https://juliaweb.github.io/HTTP.jl/stable/>

- [16] JLD2.jl Documentation. *JLD2.jl : HDF5-compatible data storage for Julia*. <https://juliaio.github.io/JLD2.jl/stable/>
- [17] P. Glasserman, *Monte Carlo Methods in Financial Engineering*, Springer, 2004.
- [18] Julia Documentation. *The Julia Programming Language*. <https://docs.julialang.org>
- [19] JuliaStats. *StatsBase.jl Documentation*. <https://juliastats.org/StatsBase.jl/stable/>
- [20] B. Legat, O. Dowson, D. Lubin, and J. P. Vielma, *MathOptInterface : a data structure for mathematical optimization problems*, <https://jump.dev/MathOptInterface.jl/stable/>
- [21] D. Lubin, O. Dowson, J. Garcia, J. Huchette, B. Legat, and J. P. Vielma, *JuMP 1.0 : Recent improvements to a modeling language for mathematical optimization*, Mathematical Programming Computation, 15, pp. 581–589, 2023.
- [22] Plots.jl Documentation. <https://docs.juliaplots.org/stable/>
- [23] Stooq Financial Database. <https://stooq.com>

Références associées aux cellules de code

Chapitre 1

`code_fichiercsv_prix.ipynb` : **Collecte des données**

- ★ **Cellule 1.1.1** : Environnement Julia et bibliothèques de traitement de données ([12], [13], [15], [18], [22], [23])
- ★ **Cellule 1.1.2** : Téléchargement de données financières (HTTP + CSV) ([12], [13], [15], [23])
- ★ **Cellule 1.1.3** : Validation du téléchargement et inspection des données ([13], [23])
- ★ **Cellule 1.1.4** : Construction du panel de prix (jointures, sélection) ([13], [23])
- ★ **Cellule 1.1.5** : Contrôle qualité des données (tri, valeurs manquantes, positivité) ([13], [18])
- ★ **Cellule 1.1.6** : Sauvegarde du panel de données au format CSV ([12])
- ★ **Cellule 1.1.7** : Visualisation des séries de prix journaliers ([22])
- ★ **Cellule 1.1.8** : Calcul des rendements simples et logarithmiques ([5], [7])
- ★ **Cellule 1.1.9** : Visualisation des log-rendements et estimation des volatilités annualisées ([5], [7])

`code_chap1.ipynb` : **Optimisation de portefeuille**

- ★ **Cellule 1.2.1** : Environnement de calcul pour l’optimisation de portefeuille ([13], [14], [18], [20], [21], [22])
- ★ **Cellule 1.2.2** : Chargement et validation des données depuis un fichier CSV ([12], [13])
- ★ **Cellule 1.2.3** : Calcul des rendements financiers ([5], [7])
- ★ **Cellule 1.2.4** : Construction des matrices de rendements ([5], [7])

- ★ **Cellule 1.2.5** : Estimation des moments (moyenne et covariance) et annualisation ([5], [6], [7])
- ★ **Cellule 1.2.6** : Visualisation des prix et des log-rendements ([22])
- ★ **Cellule 1.2.7** : Optimisation moyenne-variance pénalisée sous contraintes long-only ([6], [7], [8], [14], [20], [21],)
- ★ **Cellule 1.2.8** : Discrétisation du paramètre d'aversion au risque ([6], [8])
- ★ **Cellules 1.2.9–1.2.10** : Calcul de la frontière efficiente à partir des rendements logarithmiques et simples ([6], [8], [14], [21])
- ★ **Cellule 1.2.11** : Benchmark équipondéré ([5])
- ★ **Cellule 1.2.12** : Passage rendement-richesse et capitalisation ([5], [8])
- ★ **Cellule 1.2.13** : Extraction d'un tableau synthétique de la frontière efficiente ([6])
- ★ **Cellule 1.2.14** : Export des résultats et tables au format CSV ([12])
- ★ **Cellule 1.2.15** : Visualisation de la frontière efficiente et comparaison avec le portefeuille équipondéré ([6], [8], [22])
- ★ **Cellule 1.2.16** : Évolution des poids optimaux en fonction de l'aversion au risque ([6], [8], [22])
- ★ **Cellule 1.2.17** : Richesse attendue en fonction de l'aversion au risque ([8], [7], [22])
- ★ **Cellule 1.2.18** : Comparaison portefeuille optimisé et benchmark équipondéré ([5], [6])
- ★ **Cellule 1.2.19** : Construction du tableau des poids optimaux ([6], [13])

Chapitre 2

`code_chap2.ipynb` : **optimisation sous mesure de risque CVaR**

- ★ **Cellule 2.1** : Environnement de calcul pour l'optimisation de portefeuille sous contrainte de risque ([9], [10], [13], [14], [18], [21], [22])
- ★ **Cellule 2.2** : Chargement et validation des données de prix ([12], [13])
- ★ **Cellule 2.3** : Vérification de la qualité des données de prix ([13], [18])
- ★ **Cellule 2.4** : Calcul des rendements financiers ([5], [7])
- ★ **Cellule 2.5** : Construction des matrices de rendements ([5], [7])
- ★ **Cellule 2.6** : Visualisation des log-rendements ([22])
- ★ **Cellule 2.7** : Construction de scénarios historiques pour l'approximation SAA ([9], [11])
- ★ **Cellule 2.8** : Estimation du rendement moyen des actifs ([5], [7])
- ★ **Cellule 2.9** : Formulation et résolution du problème CVaR-SAA pénalisé ([9], [10], [11], [14], [21])
- ★ **Cellule 2.10** : Grille logarithmique du paramètre de risque ([6], [9])
- ★ **Cellule 2.11** : Résolution du problème CVaR-SAA sur une grille de paramètres ([9], [10], [11], [14], [21])
- ★ **Cellule 2.12** : Calcul empirique de la CVaR et benchmark équipondéré ([9], [11])
- ★ **Cellule 2.13** : Calcul de la richesse future à partir des rendements ([5], [8])
- ★ **Cellule 2.14** : Tableau synthétique de la frontière CVaR ([9])
- ★ **Cellule 2.15** : Frontière rendement-CVaR ([9], [11], [22])

- ★ **Cellule 2.16** : Évolution des poids optimaux sous contrainte de CVaR ([9], [22])
- ★ **Cellule 2.17** : Richesse attendue sous optimisation CVaR ([8], [9], [22])
- ★ **Cellule 2.18** : Comparaison portefeuille optimisé (CVaR) et équipondéré ([5], [9])
- ★ **Cellule 2.19** : Comparaison des trajectoires de richesse réalisées sous stratégies MV, CVaR et équipondérée ([6], [9], [14], [21], [22])

Chapitre 3

code_chap3.ipynb : optimisation contextuelle et analyse comparative

- ★ **Cellule 3.1** : Environnement de calcul pour l'optimisation de portefeuille et la gestion des résultats ([13], [14], [18], [20], [21], [22])
- ★ **Cellule 3.2** : Chargement et validation des données de prix ([12], [13])
- ★ **Cellule 3.3** : Vérification de la qualité des données de prix ([13], [18])
- ★ **Cellule 3.4** : Calcul des rendements financiers ([5], [7])
- ★ **Cellule 3.5** : Construction des matrices de rendements ([5], [7])
- ★ **Cellule 3.6** : Visualisation des log-rendements ([22])
- ★ **Cellule 3.7** : Construction d'un facteur de volatilité et filtrage des données contextuelles ([4], [5])
- ★ **Cellule 3.8** : Discrétisation du contexte en régimes de volatilité ([4], [19])
- ★ **Cellule 3.9** : Visualisation du contexte de volatilité et des seuils de régimes ([4], [22])
- ★ **Cellule 3.10** : Estimation des moments conditionnels par régime de volatilité ([4], [7])
- ★ **Cellule 3.11** : Résolution du problème moyenne-variance pénalisé ([6], [8], [14], [21])
- ★ **Cellule 3.12** : Résolution du problème CVaR pénalisé ([9], [10], [11], [14], [21])
- ★ **Cellule 3.13** : Fonctions de richesse réalisée et de CVaR empirique ([8], [9])
- ★ **Cellule 3.14** : Comparaison sur grille des stratégies MV statique, CVaR statique et MV contextuelle ([4], [6], [9], [14], [21])
- ★ **Cellule 3.15** : Benchmark équipondéré pour comparaison des stratégies ([5], [9])
- ★ **Cellule 3.16** : Calcul de la richesse attendue des différentes stratégies ([5], [8])
- ★ **Cellule 3.17** : Comparaison de la richesse attendue selon les stratégies ([8], [22])
- ★ **Cellule 3.18** : Comparaison dynamique des stratégies pour une valeur donnée de η ([4], [6], [9])
- ★ **Cellule 3.19** : Comparaison des trajectoires de richesse réalisées ([4], [6], [9], [22])
- ★ **Cellule 3.20** : Comparaison des trajectoires de richesse en échelle logarithmique ([8], [22])
- ★ **Cellule 3.21** : Tableau comparatif des performances des stratégies ([6], [9])
- ★ **Cellule 3.22** : Analyse synthétique de la domination de la stratégie contextuelle selon η ([13], [4], [6], [9], [22])

Chapitre 4

`code_chap4_generation_scenarios.ipynb` : **génération de scénarios de marché**

- ★ **Cellule 4.1.1** : Initialisation de l'environnement de calcul pour la génération de scénarios ([12], [13], [16], [18], [19], [22])
- ★ **Cellule 4.1.2** : Paramétrage de la simulation Monte Carlo et du cadre expérimental ([17], [18])
- ★ **Cellule 4.1.3** : Chargement et validation des données de prix ([12], [13])
- ★ **Cellule 4.1.4** : Contrôle de qualité des données de prix ([13], [18])
- ★ **Cellule 4.1.5** : Définition des rendements simples et logarithmiques ([5], [18])
- ★ **Cellule 4.1.6** : Construction des matrices de rendements à partir des prix ([5], [13])
- ★ **Cellule 4.1.7** : Visualisation des log-rendements des actifs ([22])
- ★ **Cellule 4.1.8** : Construction d'un proxy de marché équipondéré ([5])
- ★ **Cellule 4.1.9** : Construction du contexte de volatilité par fenêtre glissante ([4], [19])
- ★ **Cellule 4.1.10** : Discrétisation du contexte en régimes de volatilité ([4], [19])
- ★ **Cellule 4.1.12** : Estimation des paramètres globaux et conditionnels par régime ([4], [5])
- ★ **Cellule 4.1.13** : Tableau des rendements moyens conditionnels par régime ([12], [13])
- ★ **Cellule 4.1.14** : Tableau des variances conditionnelles par régime ([12], [13])
- ★ **Cellule 4.1.15** : Estimation de la matrice de transition des régimes ([4])
- ★ **Cellule 4.1.16** : Décomposition de Cholesky régularisée des matrices de covariance par régime ([5], [18])
- ★ **Cellule 4.1.17** : Définition des fonctions de simulation de régimes, rendements et prix ([4], [5], [18], [19])
- ★ **Cellule 4.1.18** : Génération de scénarios Monte Carlo conditionnels aux régimes ([4], [17])
- ★ **Cellule 4.1.19** : Validation empirique des scénarios simulés ([13], [17])
- ★ **Cellule 4.1.20** : Visualisation d'un scénario simulé de trajectoires de prix ([17], [22])
- ★ **Cellule 4.1.21** : Visualisation de multiples trajectoires simulées pour un actif ([17], [22])
- ★ **Cellule 4.1.22** : Sauvegarde des objets du générateur de scénarios ([16], [18])

`code_chap4_optimisation_portfeuille.ipynb` : **optimisation de portefeuille à partir des scénarios simulés**

- ★ **Cellule 4.2.1** : Initialisation de l'environnement de calcul pour l'optimisation de portefeuille sur scénarios simulés ([13], [14], [16], [18], [21], [22])
- ★ **Cellule 4.2.2** : Définition des paramètres globaux et de la grille de pénalisation ([18])
- ★ **Cellule 4.2.3** : Chargement des scénarios simulés pour l'optimisation ([16], [18])
- ★ **Cellule 4.2.4** : Chargement des données historiques pour l'évaluation ([12], [13])

- ★ **Cellule 4.2.5** : Définition des fonctions de rendements ([5], [18])
- ★ **Cellule 4.2.6** : Construction des matrices de rendements historiques ([5], [13])
- ★ **Cellule 4.2.7** : Reconstruction du contexte historique de volatilité et des régimes ([4], [19])
- ★ **Cellule 4.2.8** : Estimation des paramètres historiques globaux et conditionnels ([4], [5])
- ★ **Cellule 4.2.9** : Fonctions utilitaires d'évaluation des stratégies (richesse, CVaR, Sharpe, drawdown) ([5], [9])
- ★ **Cellule 4.2.10** : Résolution du problème moyenne-variance pénalisé sous contraintes long-only ([6], [7], [8], [14], [20], [21])
- ★ **Cellule 4.2.11** : Résolution du problème CVaR pénalisé à partir de scénarios simulés (formulation SAA) ([9], [10], [11], [14], [20], [21])
- ★ **Cellule 4.2.12** : Résolution du problème contextuel moyenne-variance pénalisé sur scénarios simulés de log-rendements ([4], [6], [7], [14], [17], [20], [21])
- ★ **Cellule 4.2.13** : Résolution comparative sur une grille du paramètre de pénalisation pour les stratégies statiques, contextuelles et robustes sous scénarios ([4], [6], [9], [10], [13], [14], [17], [21])
- ★ **Cellule 4.2.14** : Visualisation de la richesse finale en fonction du paramètre de pénalisation pour différentes stratégies de portefeuille ([4], [6], [9], [22])
- ★ **Cellule 4.2.15** : Extraction des portefeuilles optimaux pour une valeur donnée du paramètre de pénalisation η ([4], [6], [9])
- ★ **Cellule 4.2.16** : Calcul des rendements réalisés et des trajectoires de richesse pour les stratégies statiques, contextuelles et robustes ([4], [6], [9], [8])
- ★ **Cellule 4.2.17** : Visualisation des trajectoires de richesse réalisées pour différentes stratégies de portefeuille ([4], [6], [8], [9], [22])
- ★ **Cellule 4.2.18** : Construction d'un tableau comparatif des performances (rendement, ratio de Sharpe, drawdown, richesse finale) des stratégies de portefeuille ([4], [6], [8], [9], [12], [13])
- ★ **Cellule 4.2.19** : Définition des paramètres pour l'analyse de sensibilité (pénalisation, nombre de scénarios, taille de grille) ([11], [17])
- ★ **Cellule 4.2.20** : Calcul des rendements réalisés d'un portefeuille contextuel dépendant des régimes de marché ([4], [7])
- ★ **Cellule 4.2.21** : Analyse de sensibilité des stratégies de portefeuille par rapport au paramètre de pénalisation η ([4], [6], [9], [10], [12], [13], [17])
- ★ **Cellule 4.2.22** : Visualisation de l'analyse de sensibilité de la richesse finale en fonction du paramètre η ([4], [6], [9], [22])
- ★ **Cellule 4.2.23** : Extraction d'un sous-échantillon de scénarios pour l'optimisation et l'analyse de sensibilité ([11], [17])
- ★ **Cellule 4.2.24** : Analyse de sensibilité de la stratégie robuste en fonction du nombre de scénarios simulés ([11], [12], [13], [14], [17], [21])
- ★ **Cellule 4.2.25** : Visualisation de la sensibilité de la richesse finale au nombre de scénarios simulés ([11], [17], [22])
- ★ **Cellule 4.2.26** : Reconstruction du contexte de volatilité et des régimes de marché à partir d'une fenêtre glissante ([4], [5], [19])
- ★ **Cellule 4.2.27** : Analyse de sensibilité de la stratégie contextuelle par rapport à la taille de fenêtre utilisée pour construire le contexte de volatilité ([4], [5], [6], [12], [13], [19])

- ★ **Cellule 4.2.28** : Visualisation de la sensibilité de la stratégie contextuelle à la taille de la fenêtre de volatilité ([4], [22])
- ★ **Cellule 4.2.29** : Synthèse des analyses de sensibilité du modèle (paramètre de pénalisation, nombre de scénarios, fenêtre de volatilité) ([4], [11], [17])
- ★ **Cellule 4.2.30** : Comparaison multi-graphique des trajectoires de richesse pour plusieurs valeurs du paramètre de pénalisation η ([4], [6], [8], [9], [10], [17], [22])
- ★ **Cellule 4.2.31** : Comparaison multi-graphique des trajectoires de richesse en fonction du nombre de scénarios simulés M ([4], [6], [8], [9], [10], [11], [17], [22])
- ★ **Cellule 4.2.32** : Comparaison multi-graphique des trajectoires de richesse en fonction de la fenêtre de volatilité K utilisée pour construire le contexte ([4], [5], [6], [8], [22])